

國立中央大學

資訊工程學系
碩士論文

融合自然語言處理與 Transformer 模型之中文至自然手語翻譯系統

A Chinese-to-Natural Sign Language Translation
System Integrating NLP and Transformer Models

研究生：朱禹丞

指導教授：蘇木春 博士

中華民國一百一十四年六月

國立中央大學圖書館學位論文授權書

填單日期：2025 / 7 / 31

2019.9 版

授權人姓名	朱禹丞	學號	112522093
系所名稱	資訊工程學系	學位類別	☒ 碩士 ☐ 博士
論文名稱	融合自然語言處理與Transformer模型之中文至自然手語翻譯系統	指導教授	蘇木春

學位論文網路公開授權

授權本人撰寫之學位論文全文電子檔：

- 在「國立中央大學圖書館博碩士論文系統」
 - ☒同意立即網路公開
 - ☐同意 於西元_____年_____月_____日網路公開
 - ☐不同意網路公開，原因是：_____
- 在國家圖書館「臺灣博碩士論文知識加值系統」
 - ☒同意立即網路公開
 - ☐同意 於西元_____年_____月_____日網路公開
 - ☐不同意網路公開，原因是：_____

依著作權法規定，非專屬、無償授權國立中央大學、台灣聯合大學系統與國家圖書館，不限地域、時間與次數，以文件、錄影帶、錄音帶、光碟、微縮、數位化或其他方式將上列授權標的基於非營利目的進行重製。

學位論文紙本延後公開申請 (紙本學位論文立即公開者此欄免填)

本人撰寫之學位論文紙本因以下原因將延後公開

- 延後原因
 - ☐已申請專利並檢附證明，專利申請案號：_____
 - ☐準備以上列論文投稿期刊
 - ☐涉國家機密
 - ☐依法不得提供，請說明：_____

公開日期：西元_____年_____月_____日

※繳交教務處註冊組之紙本論文(送繳國家圖書館)若不立即公開，請加填「國家圖書館學位論文延後公開申請書」

研究生簽名：朱禹丞

指導教授簽名：蘇木春

國立中央大學碩士班研究生 論文指導教授推薦書

資訊工程學系碩士班 學系/研究所 朱禹丞 研究生

所提之論文 融合自然語言處理與 Transformer 模型之中文至自然
手語翻譯系統

係由本人指導撰述，同意提付審查。

指導教授 葉木君 (簽章)

114 年 6 月 18 日

國立中央大學碩士班研究生 論文口試委員審定書

資訊工程學系碩士班 學系/研究所 朱禹丞 研究生

所提之論文 融合自然語言處理與 Transformer 模型之中文至自然
手語翻譯系統

經由委員會審議，認定符合碩士資格標準。

學位考試委員會召集人

委

員

李揚漢
許頌岡
魏木君

中 華 民 國

114 年

7 月

9 日

融合自然語言處理與 Transformer 模型之中文至自然手語翻譯系統

摘要

根據 2024 年底衛福部統計資料顯示，台灣登記在案的聽覺機能障礙者（Hearing Impairment）人數已達 138,966 人。這些聽障人士在日常生活中，主要依賴台灣自然手語（Taiwan Sign Language, TSL）進行溝通。然而，一般民眾在學習手語時，通常是透過手語書或課程學習文法式、結構化的手語，其語言表達方式與自然手語差異甚大，造成聽障人士與聽人的溝通往往出現理解困難與落差。提升一般人對自然手語的理解與應用，有助於促進更順暢的雙向溝通，進而實踐資訊無障礙的理念。

為此，本文提出一種將書面中文自動轉換為自然手語的系統，協助聽人能更有效地表達出聽障人士熟悉的自然手語句型。系統採用基於 Transformer 架構的深度學習方法，透過平行語料訓練模型，自動學習中文與自然手語之間的對應關係。此外，本研究結合自然語言處理（NLP）工具，對輸入中文句進行詞性標註、依存句法分析、成分句法分析與斷詞處理，以協助模型掌握語法與語意特徵，提升轉換品質。

實驗結果顯示，本系統能有效處理多種中文語句類型，並能正確調整語序與詞彙，生成貼近自然手語表達邏輯的輸出內容。此方法未來可應用於手語教學輔助系統、跨語言溝通平台或公共服務場域，具備實質的社會應用潛力與推廣價值。

關鍵字：中文轉換, Transformer, 手語翻譯, 自然手語, 自然語言處理

A Chinese-to-Natural Sign Language Translation System Integrating NLP and Transformer Models

Abstract

According to statistics from Taiwan’s Ministry of Health and Welfare at the end of 2024, there are 138,966 registered individuals with hearing impairments. In their daily lives, these individuals primarily rely on Taiwan Sign Language (TSL) for communication. However, most hearing individuals learn sign language through books or structured courses, which are based on formalized and grammatical versions of sign language that differ significantly from natural TSL. This discrepancy often leads to communication gaps and misunderstandings between hearing and deaf individuals. Enhancing the general public’s understanding and use of natural sign language can facilitate smoother two-way communication and promote the concept of information accessibility.

To address this issue, this study proposes a system that automatically translates written Mandarin Chinese into natural TSL expressions, helping hearing individuals convey messages in a form more familiar to the deaf community. The system employs a deep learning approach based on the Transformer architecture, learning the mapping between Mandarin and natural sign language through parallel corpora. Additionally, natural language processing (NLP) tools are integrated to perform part-of-speech tagging, dependency parsing, constituency parsing, and word segmentation on the input text, enabling the model to better capture syntactic and semantic features and improve translation quality.

Experimental results show that the system can effectively handle various types of Chinese sentences, accurately adjust word order and vocabulary, and generate output aligned with the logic of natural TSL expression. This approach holds practical potential for applications such as sign language education tools, cross-linguistic communication platforms, and public service systems.

Keywords: Chinese-to-Sign Translation, Transformer, Sign Language Translation, Natural Sign Language, Natural Language Processing

誌謝

從大學進入中央以來，轉眼已過六年，終於迎來碩士階段的尾聲。在此，謹向所有在這段旅程中給予我支持、鼓勵與協助的每一位，致上最誠摯的感謝。

首先，衷心感謝我的指導教授蘇木春老師，在這兩年的研究歷程中，老師不僅提供我明確的研究方向，更在每次討論中耐心指導，讓我能夠逐步釐清思路、深化研究。因為老師的引導與鼓勵，我得以不斷成長，順利完成論文，深感幸運與感激。

感謝實驗室的每一位成員，陪伴我度過充實又難忘的兩年時光。特別感謝熙琪、佳菁與小花對實驗室事務的協助，讓一切能夠順利進行，尤其熙琪在英語計畫上的幫忙，更令我受益良多。感謝致輔、時富、建名、妤潔、嘉彤、名誼與威任，在我初入實驗室時提供悉心協助與引導。感謝宜歡、崇祐、宗祐、俊宇、宥俞，彼此在研究生活中互相扶持、陪伴與激勵，使這段碩士生涯更加精彩。也感謝容瑄、佳妤、育萱、寶涵與逸凡接續實驗室的日常運作，讓實驗室持續發展與進步。最後，謝謝碩予、立洋與裕倫，讓我在中央擁有一段美好而難忘的回憶。謝謝大家的陪伴與幫助，讓我的研究歷程豐富而難忘。

最後，最深的感謝獻給我的家人。感謝你們在我求學過程中始終如一的支持與鼓勵，讓我在遇到挑戰與低潮時仍能堅持下去。你們的陪伴是我持續前進的最大動力，成就了今天的我，衷心說聲謝謝你們。

臺灣學術倫理教育資源中心

修課證明

證書第 S112063343 號

國立中央大學


朱禹丞 Chu Yu-Cheng

茲證明 已修畢臺灣學術倫理教育資源中心之「學術研究倫理教育課程」，並通過課程總測驗，修課時數累積共 6 小時 0 分鐘。

修業課程單元 (20 分鐘／單元)	測驗通過日期
0101_研究倫理定義與內涵	114/04/30
0102_研究倫理專業規範與個人責任	114/04/30
0103_研究倫理的政府規範與政策	114/04/30
0104_不當研究行為：定義與類型	114/04/30
0105_不當研究行為：造假與變造資料	114/04/30
0106_不當研究行為：抄襲與剽竊	114/04/30
0107_不當研究行為：自我抄襲	114/04/30
0108_學術寫作技巧：引述	114/04/30
0109_學術寫作技巧：改寫與摘寫	114/04/30
0110_學術寫作技巧：引用著作	114/04/30
0111_論文作者定義與掛名原則	114/04/30
0112_著作權基本概念	114/04/30
0113_個人資料保護法基本概念	114/04/30
0114_隱私權基本概念	114/04/30
0115_受試者保護原則與實務	114/04/30
0116_研究資料管理概述	114/04/30
0201_研究中的利益衝突	114/04/30
0207_學術研究者的社會責任	114/04/30

此證

檢驗



中 華 民 國 114 年 4 月 30 日

課表：基礎課程

學員：112-碩士班-中文版-112522093 下載日期：114/04/30 12:42:59

目錄

	頁次
摘要	iv
Abstract	v
誌謝	vii
目錄	xi
一、緒論	1
1.1 研究動機	1
1.2 研究目標	2
1.3 論文架構	3
二、背景知識以及文獻回顧	4
2.1 文獻回顧	4
2.1.1 深度學習應用於翻譯之相關研究	4
2.1.2 翻譯文本至手語之相關研究	7
2.2 背景知識	10
2.2.1 台灣手語	10
2.2.2 手語種類	11
2.2.3 自然語言處理介紹	12
2.2.4 Transformer 介紹	13
2.2.5 參數高效微調技術：LoRA	15
2.2.6 BLEU 分數	16

2.2.7	ROUGE 分數	18
三、	研究方法	20
3.1	資料集	20
3.1.1	手語與口語平行語料	20
3.1.2	手語辭彙庫	21
3.2	系統架構	22
3.3	前處理	23
3.3.1	資料擴增	23
3.3.2	CKIP 斷詞	25
3.3.3	NLP 分析	26
3.4	模型架構	28
3.4.1	MarianMT、T5 與 mT5 模型架構	28
3.4.2	語言結構增強的模型設計	30
3.4.3	基於 LoRA 的 Adapter 架構實作	32
3.5	結構提示設計	34
3.6	後處理	35
3.7	使用者介面	36
四、	實驗設計與結果	38
4.1	實驗流程與評估指標	38
4.2	實驗環境與參數設定	39
4.2.1	不同模型結果	40
4.2.2	不同 Embedding 方式比較	42
4.2.3	不同 Prompt 方式比較	43
4.2.4	Adapter 架構添加比較	44
4.2.5	擴增資料集比較	48

4.3	結果呈現與分析	50
4.3.1	模型效能驗證	50
4.3.2	錯誤案例分析	56
五、	總結	60
5.1	結論	60
5.2	未來展望	61
	參考文獻	62
	附錄 A CKIP 詞性標註對照表	66
	附錄 B HanLP 標記對照表	69

圖目錄

	頁次
2.1 台灣手語南北部”十”差異 [20]	10
2.2 Transformer 架構，摘自 [3]	14
3.1 手語翻譯培訓教材內容範例	20
3.2 資料集中各長度區間的樣本數分布	21
3.3 手語辭彙庫內容示意	22
3.4 系統架構圖	23
3.5 擴增後資料集中各長度區間的樣本數分布	24
3.6 擴增前後資料集長度分布對比	25
3.7 修改後的 mT5 模型 (add)	31
3.8 修改後的 mT5 模型 (cat)	31
3.9 本系統整體架構	36
3.10 本系統之 GUI 介面。	37
4.1 擴增資料集前後測試集分數對比	49
4.2 GUI 結果展示 1	51
4.3 GUI 結果展示 2	52
4.4 GUI 結果展示 3	53
4.5 GUI 結果展示 4	54
4.6 GUI 結果展示 5	56
4.7 再訓練後正確輸出展示	58

表目錄

	頁次
2.1 主要神經機器翻譯模型比較	6
2.2 基於翻譯文本至手語相關研究數據整理	9
2.3 自然手語與文法手語的差異範例	12
3.1 手語辭彙集來源與詞彙數量	22
3.2 CKIP 前處理結果示意	26
3.3 HanLP 前處理結果示意	27
3.4 T5 模型架構	29
3.5 T5-Chinese、mT5-Base 與 MarianMT 模型架構比較	30
3.6 修改後 mT5-Base 模型架構	32
3.7 自動組合詞替換示意	35
4.1 不同基礎模型在資料集上的效能對比*	41
4.2 不同 Embedding 融合方式對模型效能之影響	42
4.3 不同 Prompt 組合在訓練集與測試集上的效能表現	43
4.4 不同微調策略下的模型效能表現比較	45
4.5 不同微調策略的模型訓練效率比較	46
4.6 訓練疊代中各計算環節的時間佔比分析	47
4.7 擴增資料集後，不同 Prompt 組合在訓練集與測試集上的 效能表現	49
4.8 模型輸出比對 1	51

4.9	模型輸出比對 2	52
4.10	模型輸出比對 3	54
4.11	模型輸出比對 4	55
4.12	模型輸出比對 5	57
4.13	再訓練後模型輸出比對	58
A.1	詞性標註對應索引表 [35]	66
B.1	依存句法標記對照表 [36]	69
B.2	成分句法標記對照表 [37]	71

一、緒論

1.1 研究動機

根據衛福部 2025 年初的統計資料 [1]，台灣已有超過 13 萬名登記在案的聽覺機能障礙者，顯示聽障群體在人口結構中占有一定比例，值得社會高度關注。對這些聽障人士而言，台灣手語（Taiwan Sign Language, TSL）[2] 是日常生活中最主要且自然的溝通工具，其語序、表達方式與中文截然不同，具有獨特的語言結構與文化背景。然而，社會大眾學習手語時，往往是透過教材或正式課程習得文法式、結構化的手語，這類手語更接近書面語言的邏輯，與聽障者實際使用的自然手語存在顯著差異。此一語言形式的落差，常導致聽人與聽障者在溝通過程中出現理解困難、語意誤解，甚至交流中斷，不僅影響彼此的互動品質，也限制聽障者在教育、就業與公共參與等方面的資訊獲取與權益保障。

近年來，隨著深度學習技術的快速發展，特別是以 Transformer [3] 架構為基礎的神經網路模型，已廣泛應用於語言翻譯、對話生成與語意理解等領域，為語言間的自動轉換提供了強大工具。此外，搭配自然語言處理（NLP）[4] 技術，如詞性標註、斷詞、句法分析等，可進一步協助模型理解語法與語意結構，提升轉換的準確性與語言邏輯性。

因此，本研究旨在縮短上述語言鴻溝，提升聽人對自然手語的理解與表達能力，協助其使用聽障者所熟悉的語言模式進行溝通。透過建置一套整合深度學習與 NLP 分析的自然手語轉換系統，不僅能增進語言轉換的自然度與可理解性，更能實現跨語言的無障礙溝通。

1.2 研究目標

本研究旨在建構一套結合深度學習與自然語言處理技術的自然手語轉換系統，協助聽人以更貼近聽障者實際語言使用的方式進行溝通。具體目標如下：

- 使用 CKIP LAB 所研發的 Transformer 模型 [5] 進行中文斷詞與詞性標註
- 使用 HanLP [6] 處理依存句法分析與成分句法分析
- 使用深度學習的方法，訓練出能夠將書面用語轉換至自然手語的模型。
- 優化轉換手語的效果，提升模型的準確率。

1.3 論文架構

本論文分為五個章節，其架構如下：

第一章、緒論，敘述本論文之研究動機以及架構。

第二章、背景知識以及文獻回顧，介紹台灣手語的相關知識，敘述本研究之背景知識如各種手語、自然語言處理 [4]、Transformer 模型 [3]，以及手語相關文獻研究。

第三章、研究方法，說明本研究細節，如資料前處理方式以及模型架構。

第四章、實驗設計與結果，說明實驗使用的資料集、實驗配置，並對於實驗結果進行分析和探討。

第五章、總結，對於研究結果進行總結，並討論研究的未來展望。

二、 背景知識以及文獻回顧

2.1 文獻回顧

本章將回顧與本研究主題相關之研究成果，主要分為兩個方向。首先介紹深度學習技術於機器翻譯領域的應用與發展，探討其從早期 Seq2Seq 架構到現今多語言預訓練模型的演進過程；其次，聚焦於中文文本轉換為手語之相關研究，說明目前在手語翻譯任務上的技術挑戰與現有解法。透過本章之回顧，奠定本研究模型設計與方法選擇之理論基礎。

2.1.1 深度學習應用於翻譯之相關研究

隨著深度學習技術的迅速發展，神經機器翻譯（Neural Machine Translation, NMT）已逐漸取代傳統的統計式翻譯方法，成為當前主流的翻譯架構。早期的 NMT 模型多採用序列到序列（Sequence-to-Sequence, Seq2Seq）架構，並搭配遞迴神經網路（Recurrent Neural Network, RNN）進行編碼與解碼（Sutskever 等人 [7]）。此一架構雖已展現良好的翻譯能力，但在處理長距離依賴時仍存在限制。

為解決上述問題，Bahdanau 等人 [8] 引入注意力機制（Attention Mechanism），使模型在解碼階段得以動態關注輸入序列中的關鍵詞彙，顯著提升翻譯品質。接續的研究中，Luong 等人 [9] 提出 Global 與 Local 等多種注意力機制變體，以優化不同語言對的翻譯效果。這些技術的演

進最終促成 Transformer 架構的誕生 (Vaswani 等人 [3])，該架構完全捨棄 RNN，全面採用自注意力機制 (Self-Attention) 進行特徵建構，不僅顯著提升訓練與推論效率，也在多項機器翻譯任務中大幅超越先前方法。

目前在 Transformer 架構基礎上，許多具有代表性的 NMT 模型相繼問世：

MarianMT (Junczys-Dowmunt 等人 [10]) 為 Microsoft 推出的高性能開源神經機器翻譯系統，專為多語言翻譯任務所設計。該模型基於 Transformer 架構，並針對多語言語料進行訓練，透過多任務學習與參數共享的方式，有效提升對低資源語言的翻譯能力。

mBART (Liu 等人 [11]) 則採用多語言去噪自編碼預訓練方法，透過對多語語料的編碼與解碼學習，強化模型於跨語言環境中的泛化能力。該模型在低資源語言的翻譯任務中表現尤為優異，驗證了跨語言預訓練策略的可行性，對多語言翻譯技術之發展具有重要貢獻。

T5 (Raffel 等人 [12]) 為 Google 提出的通用文字轉換架構，主張將所有自然語言處理任務統一轉化為「文字到文字」(Text-to-Text) 的形式。T5 採用 Encoder-Decoder 結構，並於大規模語料集 (如 C4) 上進行預訓練，再針對下游任務進行微調，展現出優異的遷移學習能力與語言理解表現，在多語言翻譯、摘要、問答等多項任務中皆有卓越表現。

整體而言，自 Bahdanau 等人提出注意力機制以來，神經機器翻譯技術經歷了快速演進。從初期的 RNN 架構發展至全注意力架構的 Transformer，再延伸至支援多語與低資源語言的現代模型如 MarianMT [10]、mBART [11] 與 T5 [12]，NMT 模型不僅顯著提升翻譯品質，也大幅拓展其應用範疇。本研究亦參考上述模型架構與訓練策略，作為手語翻譯模型設計與優化之基礎。

表 2.1 彙整了上述各代表性神經機器翻譯模型的核心特點與技術概要：

表 2.1: 主要神經機器翻譯模型比較

模型名稱	提出年份	核心技術	特色簡述
Seq2Seq [7]	2014	RNN + LSTM	最早使用編碼器-解碼器架構進行翻譯
Bahdanau Attention [8]	2015	Attention + RNN	加入注意力機制，改善長距依賴問題
Luong Attention [9]	2015	Global/Local Attention	精緻化注意力設計，提升翻譯精度
Transformer [3]	2017	Self-Attention	拋棄 RNN，提升效率與翻譯表現
MarianMT [10]	2018	多語訓練 + 高效 C++ 實作	高效開源框架，強化多語與低資源語言翻譯能力
mBART [11]	2020	Denoising Pre-training	多語言編碼-解碼預訓練，擅長處理低資源語言翻譯任務
T5 [12]	2020	Text-to-Text + Span Corruption	將所有任務格式統一為文字轉文字，具強大遷移學習能力

2.1.2 翻譯文本至手語之相關研究

由於手語屬於視覺語言，且其語法結構與口語語言差異顯著，傳統的端對端機器翻譯模型（End-to-End NMT）在處理文本轉手語書寫（Text-to-Gloss）任務時，面臨語料稀缺、語序差異與語義對齊困難等挑戰。近年來，相關研究多聚焦於結合深度學習技術與語言學特徵，以提升模型對手語語言特性的擬合能力。

Younes Ouargani 等人於其研究中指出 [13]，針對 Text-to-Gloss 任務，提出一套基於 Transformer 架構的「連續式超參數探索（Consecutive Hyper-parameter Exploration）」方法，透過系統化調整模型的層數、注意力頭數、詞嵌入維度與 Dropout 比率等超參數，提升模型在低資源語言情境下的表現，證明了細緻調參與模型可擴展性對翻譯品質的提升具顯著貢獻。

另一方面，Egea Gómez 等人提出一種語法感知（Syntax-Aware）之 Transformer 架構 [14]，在編碼器階段引入依存語法關係，將其向量化並與詞嵌入相加，從而增強模型對句法結構的理解。此法無須大幅增加運算成本，卻能顯著提升翻譯準確度，顯示語法資訊對於建構語義一致之 Gloss 表達形式具備潛在價值。

此外，Zhu 等人於 ACL 2023 提出整合多種低資源翻譯技術（資料增強、半監督學習、遷移學習與多語翻譯模型）之研究框架 [15]，成功應用於德語轉德國手語（DGS）與美國手語（ASL）之 Gloss 翻譯任務。其實驗證明，透過多語模型配合反向翻譯策略，可於 Phoenix-Weather 2014T 資料集上提升超過 6 BLEU 分數，為目前最佳表現之一，並經人工評估進一步驗證翻譯品質之提升。

而 Abdullah 等人於 2025 年針對孟加拉語（Bangla）提出一套以 mBART 模型為核心的 Text-to-Gloss 系統 [16]，該研究為首度探討 Bangla 到手語 Gloss 的轉換任務。作者針對資料稀缺問題，結合規則式 gloss 產生、GPT-4o 合成資料、多語語料整合與資料增強等策略構建訓練資料

集，並比較多種模型架構（如 mBERT、GRU、RNN、Seq2Seq）之效果。實驗結果顯示，mBART 由於預訓練時已具備遮蔽與打亂輸入的能力，特別適合 Gloss 這類語序彈性高的目標語言，在 Bangla-Gloss 資料集上達成 SacreBLEU 79.53，亦於 PHOENIX14T 基準測試中創下 63.89 的表現，明顯優於既有文獻方法。

綜上所述，將語言學結構（如依存語法、詞性標記等）導入 Transformer 類模型，或善用低資源機器翻譯領域常見的合成資料與多語訓練技術，均能有效提升 Text-to-Gloss 系統之翻譯品質與穩定性。這些研究指出，Gloss 作為手語生成任務的中介形式，在多語言、多模態自然手語轉換系統中，具有關鍵地位與應用潛力。在介紹各研究成果的同時，也須考量其所使用的資料集對結果的影響。不同資料集在語言、語域、資料規模與標註品質等方面皆有所差異，進而影響模型訓練與評估的表現。以下列舉本節提及之研究中所使用之主要資料集：

- **PHOENIX14T [17]**：德國手語（DGS）之標註語料，主要為天氣預報字幕與手語對應之 Gloss，為目前最常用於手語翻譯任務之基準資料集。
- **DGS Corpus [18] [19]**：德國漢堡大學建置之德國手語大型語料庫，資料較多元但結構複雜，較少用於標準化翻譯評估。
- **Bangla Sign Language Dataset [16]**：由 Abdullah 等人基於 Bangla 語言自建之資料集，結合人工標註、LLM 合成、規則轉換與多語語料增強所得，為首個應用於 Bangla Text-to-Gloss 任務之大型混合語料庫。

表 2.2 彙整上述研究在不同資料集上的表現，涵蓋 BLEU、SacreBLEU 與 ROUGE-L 等評估指標，用以比較其翻譯品質與模型成效差異，其中未提供數據的項目以－表示，指標皆為越高越好，並將於 2.2.6 及 2.2.7 節做介紹。

表 2.2: 基於翻譯文本至手語相關研究數據整理

資料集	BLEU				SacreBLEU	ROUGE-L (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		
PHOENIX14T (Younes Ouargani 等人 [13])	63.6	28.5	15.2	9.0	—	0.5518
PHOENIX14T (Egea Gómez 等人 [14])	—	—	—	—	53.52	0.467
PHOENIX14T (Zhu 等人 [15])	—	—	—	26.32	—	—
DGS (Zhu 等人 [15])	—	—	—	5.78	—	—
PHOENIX14T (Abdullah 等人 [16])	55.14	38.07	27.13	20.68	63.89	—
Bangla Sign Language (Abdullah 等人 [16])	85.1	73.46	57.4	44.71	79.53	—
台灣手語平行語料 (Ours)	42.72	29.61	22.36	18.00	—	0.4881

2.2 背景知識

2.2.1 台灣手語

台灣手語（Taiwan Sign Language, TSL）是台灣聽障社群長期以來自然發展出的視覺-動作語言，主要透過手勢、臉部表情與身體動作來進行溝通。與中文等口語語言不同，台灣手語具有獨立且完整的語言系統，包括獨特的語音（手勢構形）、詞彙、語法與語意結構。其語序通常偏向主-賓-謂（SOV），在表達上更強調語境與空間配置，是一種高度空間化與圖像化的語言。

根據語言學研究，台灣手語的語言結構與其他自然手語，如美國手語（ASL）與日本手語（JSL），在若干層面上具有相似之處，但也發展出本地特有的表達方式與文化特徵。台灣手語的起源可追溯至日治時期，當時日本手語透過特殊教育系統傳入台灣，並隨著時間演變與在地化，逐漸形成今日所見的台灣自然手語體系。目前台灣手語分成北部手語和南部手語，兩者在部分詞彙與手勢上存在差異，圖 2.1 為台灣手語十的南部比法和北部比法比較。




圖 2.1: 台灣手語南北部”十”差異 [20]

隨著手語翻譯制度與聽障教育的推展，台灣手語已逐漸獲得社會重視，在 2018 年 12 月 25 日，《國家語言發展法》[21] 正式立法，台灣手語列入中華民國的國家語言。然而，由於社會大眾對台灣手語的了解仍有限，且常以教材式手語或書面語邏輯進行教學，使得實際溝通上常出現語言落差。因此，正確認識台灣手語的語言特性與社會功能，對於促進聽障者語言權益保障、建立平權溝通環境具有重要意義。

2.2.2 手語種類

手語是一種視覺性語言，透過手勢、身體動作、臉部表情等非語音方式進行溝通。根據其發展來源與使用情境，手語大致可分為以下三種類型：

1. **自然手語 (Natural Sign Language)**：自然手語是聾人社群在長期互動中自發形成的語言，具備完整的語言結構，包括獨立的語法、語序與詞彙系統，屬於真正的語言體系。例如台灣手語 (TSL)、美國手語 (ASL)、日本手語 (JSL) 皆屬此類。自然手語通常在聾人家庭、社群與日常生活中使用，能完整表達抽象與複雜語意。
2. **文法手語 (Manually Coded Language, MCL)**：系統化手語是一種人工設計的手語系統，目的在於將口語語言（如中文、英文）以手語形式「直譯」呈現。它往往保留原語言的語序與語法。此類手語多用於教育場合，幫助聾人學生學習書面語文，但在實際生活中較少被自然使用。
3. **手勢語言或替代手勢系統 (Gestural Systems / Home Signs)**：此類系統通常在無正式手語環境下，由個別家庭或小型社群自行創造的手勢系統，用來進行基本溝通。這些手勢雖具有部分語意功能，但缺乏系統性與語法結構，無法稱為完整語言，常見於聽障兒童未接受正規語言教育的情境中。

表 2.3: 自然手語與文法手語的差異範例

語言類型	句子範例	說明
中文原句	我在看棒球賽。	作為對照的口語語句
文法手語	我、觀賞、棒球賽。	依中文語序直譯的手語形式
自然手語	我、棒球賽、觀賞。	遵循自然手語語法與語序

上述三種手語在語言學本質與實際應用功能上具有明顯差異。自然手語作為聾人社群的主要語言工具，亦是其文化與身分認同的重要承載；相較之下，文法手語多屬輔助性質，反映的是教育體系與社會對聾人語言權益的理解與回應程度。本研究亦以自然手語為轉換目標，期望建構更貼近聾人真實語言使用的轉換系統。

2.2.3 自然語言處理介紹

自然語言處理（Natural Language Processing, NLP）[4] 是人工智慧與語言學的交叉領域，旨在使電腦能夠理解、分析、生成及操作人類自然語言。NLP 涉及的語言形式涵蓋文字與語音，其核心目的是將人類語言轉化為機器可處理的結構，並在此基礎上執行語意分析、語法判斷、資訊擷取等語言任務。

NLP 的處理流程通常包括多個階段，自底而上涵蓋如下技術：

- **文字預處理（Text Preprocessing）**：包含斷詞、去除停用詞、詞形還原（Lemmatization）等步驟，有助於統一輸入資料格式。
- **詞性標註（Part-of-Speech Tagging, POS Tagging）** [22]：為句子中的每個詞賦予其語法角色，如名詞、動詞、形容詞等，提供語法結構資訊。
- **句法分析（Syntactic Parsing）**：解析句子內部結構，如依存句法（Dependency Parsing [23]）或成分句法（Constituency Parsing），揭

示詞與詞之間的語法關聯。

- **語意理解 (Semantic Analysis)**：包括詞義消歧 (Word Sense Disambiguation)、語意角色標註 (Semantic Role Labeling) 等，用以掌握語句的語意層次。

隨著深度學習的快速發展，特別是以 Transformer 為基礎的模型（如 BERT [24]、GPT [25]、T5 [12]）問世，NLP 的表現大幅提升，使得機器在語言理解、生成與翻譯方面的能力接近人類水準。這些模型可在少量監督下學習大量語言知識，並廣泛應用於機器翻譯、聊天機器人、情感分析、語音辨識、文本摘要等實際場景。

在本研究中，NLP 技術扮演關鍵角色，透過對中文輸入的詞性、語序與語法結構的解析，協助模型準確對應手語中截然不同的語言邏輯與表達方式，進而提升中文轉自然手語的準確性與自然度。

2.2.4 Transformer 介紹

Transformer [3] 是由 Vaswani 等人於 2017 年提出的一種深度學習架構，最初用於機器翻譯任務。該模型捨棄傳統的循環神經網路 (RNN) 與卷積神經網路 (CNN) 結構，全面採用注意力機制 (Attention Mechanism) 來建構模型核心，使其在處理長距離語言依存關係與並行運算上具備極大優勢，成為現今自然語言處理 (NLP) 領域的主流模型架構。




圖 2.2: Transformer 架構，摘自 [3]

Transformer 的基本結構於圖 2.2 所示，其中以編碼器（Encoder）與解碼器（Decoder）兩大模組組成，每個模組皆由多層堆疊的子結構所構成，包括：

- **多頭自注意力機制（Multi-Head Self-Attention）**：透過多組獨立的注意力頭，並行擷取序列中不同位置間的相依關係，使模型能聚焦於輸入中與當前詞語語意最相關的上下文資訊。
- **前饋神經網路（Feed-Forward Network, FFN）**：每個位置上獨立運作的小型神經網路，用於非線性特徵轉換，提升模型表達能力。
- **殘差連接與層正規化（Residual Connection and Layer Normalization）**：有助於穩定模型訓練與加速收斂。

- **位置編碼 (Positional Encoding)**：由於 Transformer 不具備遞迴結構，需額外加入位置資訊來表示詞語的順序性。

得益於上述設計，Transformer 能夠有效捕捉語句中複雜的語法與語意結構，並支援高度並行運算，特別適用於大規模語料的訓練任務。許多後續的語言模型（如 BERT [24]、GPT [25]、T5 [12] 等）皆以 Transformer 為基礎加以改進與擴展。

在本研究中，Transformer 提供一個強大且彈性的架構，可作為中文轉自然手語任務的核心模型。透過結合詞性標註、斷詞等 NLP 技術，Transformer 能更深入理解輸入語句的結構與語意，進一步生成貼近聽障者使用習慣的手語輸出。此外，模型的可擴充性也便於後續整合多模態輸入或額外語言資訊，如上下文語境或語用標記，以提升溝通準確度與自然度。

2.2.5 參數高效微調技術：LoRA

隨著大型語言模型 (LLM) 的參數規模日益增大，對整個模型進行微調 (Full Fine-tuning) 所需的計算資源與時間成本也急劇上升。為解決此問題，參數高效微調 (Parameter-Efficient Fine-Tuning, PEFT) 技術應運而生。PEFT 的核心思想是在凍結大部分預訓練模型參數的同時，僅訓練少量額外或指定的參數，從而大幅降低微調的成本。

LoRA (Low-Rank Adaptation) [34] 是目前主流的 PEFT 技術之一。其靈感來源於一個觀察：大型模型中的權重矩陣通常具有較低的「內在維度」(Intrinsic Dimension)，意味著權重更新的變化量可以透過低秩矩陣來近似。

LoRA 的具體做法是，對於一個原始的權重矩陣 $W_0 \in \mathbb{R}^{d \times k}$ ，在微調過程中保持 W_0 不變，並額外引入兩個可訓練的低秩矩陣 $A \in \mathbb{R}^{d \times r}$ 與 $B \in \mathbb{R}^{r \times k}$ ，其中秩 (rank) $r \ll \min(d, k)$ 。模型的總體權重變化量 ΔW 則由這兩個矩陣的乘積 BA 來表示。因此，模型在前向傳播時的權重變

為：

$$W = W_0 + \Delta W = W_0 + BA \quad (2.1)$$

在實際應用中，通常還會引入一個縮放係數 α ，公式變為 $W = W_0 + \frac{\alpha}{r}BA$ 或其他變體，用以調整附加權重的影響力。透過這種方式，需要訓練的參數數量從 $d \times k$ 大幅減少至 $d \times r + r \times k$ ，實現了高效微調。訓練完成後，僅需儲存新增的矩陣 A 和 B ，極大地節省了儲存空間。

2.2.6 BLEU 分數

BLEU (Bilingual Evaluation Understudy) 分數是一種常用於自動機器翻譯評估的指標，由 Papineni 等人提出 [26]，旨在衡量機器翻譯結果與一組人工參考翻譯之間的相似程度。BLEU 分數的核心思想是透過統計方式比較 N-gram 的重疊率來評估翻譯品質，並加入簡單的懲罰機制以避免模型產生過短的輸出。

具體而言，BLEU 分數主要包含以下兩個要素：

- **N-gram Precision**：計算機器翻譯結果中與參考翻譯一致的 N-gram 比例。通常會考慮 1-gram 至 4-gram 的平均值，以兼顧語意與語法的準確性。
- **Brevity Penalty (簡短懲罰)**：為避免系統透過產生過短的句子來提高 N-gram 準確率，BLEU 分數會對比參考翻譯的長度與機器輸出長度，並對過短的輸出進行懲罰。

BLEU 分數的計算公式如下：

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (2.2)$$

其中：

- N ：最大 N-gram 的長度（常設為 4）
- w_n ：每個 N-gram 的權重，通常平均分配，即 $w_n = \frac{1}{N}$
- p_n ：第 n 階 N-gram 的精確率（Precision）
- BP：Brevity Penalty（簡短懲罰），計算方式為：

$$\text{BP} = \begin{cases} 1 & \text{if } c > r \\ e^{(1-r/c)} & \text{if } c \leq r \end{cases} \quad (2.3)$$

其中 c 為候選翻譯的長度， r 為最接近的參考翻譯長度。

BLEU 分數的值介於 0 至 1 之間，分數越高表示機器翻譯與人工翻譯越相近。在實務上，BLEU 分數常以百分比表示（例如 0.42 表示為 42 分），並廣泛應用於各類翻譯任務與模型效能比較中。

儘管 BLEU 分數在翻譯系統評估上具備快速、可重現與客觀等優點，但其也存在某些限制，例如對語義錯誤較不敏感、無法處理語序彈性過大的語言等。因此，在評估手語翻譯或多樣性輸出任務時，往往需要搭配其他評估指標共同使用，以提供更全面的效能分析。

2.2.7 ROUGE 分數

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) 是一組常用於自動摘要與自然語言生成任務的評估指標，旨在量化系統輸出與人工參考答案之間的重疊程度。ROUGE 最初由 Lin 等人提出 [27]，其設計偏重召回率 (recall)，特別適合用於評估是否涵蓋重要資訊的任務。

ROUGE 包含多種變體，常見的包括：

- **ROUGE-N**：基於 N-gram 的重疊統計，衡量系統輸出與參考文本之間的 N-gram 匹配程度，適用於單字層級的比較。
- **ROUGE-L**：基於最長共同子序列 (Longest Common Subsequence, LCS)，可捕捉語序與結構的相似性。
- **ROUGE-W**：在 ROUGE-L 的基礎上進行加權，強調連續匹配的片段。

本研究採用 **ROUGE-L** 作為翻譯品質的主要評估指標，其可有效反映模型在語句結構與語意重疊上的表現。

ROUGE-L 通過最長共同子序列 (LCS) 計算 Precision、Recall 與 F1 分數，具體定義如下：

- **Precision**：最長共同子序列長度與系統輸出長度之比。
- **Recall**：最長共同子序列長度與參考翻譯長度之比。
- **F1 分數**：Precision 與 Recall 的調和平均，用以綜合評估整體品質。

其數學公式如下：

$$P = \frac{\text{LCS}(X, Y)}{|X|} \quad (2.4)$$

$$R = \frac{\text{LCS}(X, Y)}{|Y|} \quad (2.5)$$

$$F1 = \frac{(1 + \beta^2) \cdot P \cdot R}{R + \beta^2 \cdot P} \quad (2.6)$$

其中：

- X 為系統產出文本， Y 為人工參考翻譯；
- $|X|$ 與 $|Y|$ 分別為其字數或詞數；
- $\text{LCS}(X, Y)$ 為 X 與 Y 的最長共同子序列長度；
- β 通常設為 1，表示 Precision 與 Recall 權重相同。

總結而言，ROUGE-L 提供了一種具語序與結構敏感度的自動化評估方法，適用於各類生成任務，包括摘要、翻譯及手語生成等，其簡單直觀的特性使其在自然語言處理領域中廣泛應用。

三、 研究方法

3.1 資料集

本章將介紹本研究所採用的資料來源與其應用方式。主要包含用於模型訓練的手語與口語之平行語料，以及後處理階段所依據的手語辭彙集。

3.1.1 手語與口語平行語料

本研究所使用之平行語料來源為臺北市勞動力重建運用處所編製之手語翻譯培訓教材 [28]，共兩冊。此教材為聽語翻譯訓練所設計，內容包含中文語句與其對應之臺灣自然手語。本研究從中擷取共計 512 筆具對應關係之語句對，作為模型訓練與驗證之基礎資料，教材內容展示可見圖 3.1，資料集長度數量可見圖 3.2。

今天／下午／我／一半／走了／／照顧小孩／／

今天下午我早退，因為要照顧孩子。

我倆／一同／去打籃球／／明天／可以^^

我們一起去打籃球，明天可以嗎？

**那裡／女／瘦瘦／高高／長髮／那兒／／（你／）見／有
沒有^^**

那裡，女人瘦瘦高高、長頭髮，那兒。（你）看到？

圖 3.1: 手語翻譯培訓教材內容範例。圖中展示了中文句子（白底）與其對應的手語 Gloss（灰底）的平行呈現方式。資料來源：[28]




圖 3.2: 資料集中各長度區間的樣本數分布

3.1.2 手語辭彙庫

為支持本研究的 Gloss 生成任務及後續的視覺化驗證，我們建構了一個綜合性的手語詞彙與影片資料庫。此資料庫整合自多個公開資源，不僅包含手語書寫（Gloss）與其中文對應，以及每個詞彙均配有對應的手語演示影片，具體示意可見圖 3.3。資料庫內容涵蓋生活常用詞彙、教保專業用語與學術手語，以確保其廣泛的覆蓋性。資料來源如表 3.1 所示，共計收錄 10,611 個包含影片的詞彙條目：



圖 3.3: 手語辭彙庫內容範例。圖 (a)、(b) 與 (c) 分別展示了表 3.1 所列三大資料來源的詞彙。每個詞條均包含詞彙與對應的演示影片畫面，為本研究的後處理與視覺化驗證提供基礎。

表 3.1: 手語辭彙集來源與詞彙數量

資料來源	詞彙數量
常用手語辭典（教育部）[29]	7,680
教保服務人員手語手冊（教育部）[30]	1,002
台灣手語線上辭典（中正大學）[31]	1,929
總計	10,611

這些詞彙資料在後處理階段被用來比對與替換模型產生的非手語詞彙，使最終輸出更符合實際手語使用情境，提升模型的實用性與自然度，以及在結果展示中，系統會根據輸出的 Gloss 序列，直接調用本資料庫中的對應影片，以生成完整的手語演示動畫。

3.2 系統架構

本研究所提出的系統架構如圖 3.4 所示。首先，系統將輸入的中文文本進行斷詞與自然語言處理分析，以取得詞性、語法結構等輔助資訊。接著，這些資訊將與原始文本一同作為模型訓練的輸入，進行手語書寫

生成。最後，透過後處理模組，將模型輸出轉換為符合手語語序與使用習慣的結果。以下將分別介紹系統架構中的各個組成部分。




圖 3.4: 系統架構圖

3.3 前處理

本章將介紹模型訓練前所進行的資料處理步驟，主要包含資料擴增 (Data Augmentation) 與自然語言處理 (Natural Language Processing, NLP) 相關分析。透過這些前處理手段，可有效提升資料品質，進而增強模型的學習效率與泛化能力。

3.3.1 資料擴增

為提升模型的泛化能力與訓練穩定性，本研究針對原始資料進行資料擴增處理，主要採用以下兩種方式：

- **長句切分**：針對句長明顯超出平均的樣本，依據語意與標點符號（如逗號、頓號等）進行語句切分，使每筆資料在長度上更加平均，有助於模型在訓練時的批次處理與注意力分配。
- **近義詞替換**：針對部分語句中常見的人名或稱謂（如「哥哥」、「媽媽」），替換為語意相近但角色不同的詞語（如「弟弟」、「爸爸」），以擴增語言表達的多樣性。例如：將「哥哥吃飯」替換為「弟弟吃飯」，讓模型接觸到更多不同組合的語言表達。

擴增後的資料在長度分布上也變得更為平均，如圖 3.5 所示。圖中展示了資料集中各筆樣本的長度分布情形，可觀察到多數樣本已落在合理範圍內，資料集筆數也由擴增前的 512 筆增至 753 筆，整體增幅約為 147%。




圖 3.5: 擴增後資料集中各長度區間的樣本數分布

為更清楚地展示擴增前後的變化，圖 3.6 比較了擴增處理前後的資料長度分布。可見透過上述擴增策略，有效緩解了長度過長的不均衡問題，有助於模型訓練的穩定性與效能提升。




圖 3.6: 擴增前後資料集長度分布對比

3.3.2 CKIP 斷詞

本研究在前處理階段使用 CKIP Lab 所提供的 ckip-transformers 工具套件 [5]，對輸入的中文句子進行斷詞與詞性標註。該工具基於 Transformer 架構，提供高準確度的中文自然語言處理能力，特別適合用於語言轉換任務的前處理階段。

在實作上，我們使用 ckip-transformers 中的 WS (Word Segmentation) 與 POS (Part-of-Speech Tagging) 模組，針對每個輸入句子產生：

- **分詞結果 (Tokens)**：將句子斷為具語義的詞組，便於後續模型理解。
- **詞性標註 (POS Tags)**：標示每個詞的語法角色，例如名詞、動詞、介詞等。
- **詞性索引編碼 (POS IDs)**：將詞性標註轉換為對應的數值索引，作為輔助特徵輸入模型。

這些詞性資訊能提供模型額外的語法提示，幫助提升翻譯結果中語序與結構的合理性。為更清楚說明前處理過程的輸入與輸出對應關係，表 3.2 示範了輸入句子經由 Ckip-Transformers 工具所產生的分詞、詞性標註與詞性索引編碼結果。

表 3.2: CKIP 前處理結果示意

處理項目	範例結果（輸入句：我喜歡學自然手語）
分詞（Tokens）	我、喜歡、學、自然、手語
詞性標註（POS tags）	Nh、VK、VC、Na、Na
詞性索引編碼（POS IDs）	25、42、32、13、13

表中顯示的詞性標註如 Nh（代名詞）、VK（狀態句賓動詞）、VC（動作及物動詞）、Na（普通名詞）等，均依據 CKIP 標籤集定義，詞性索引則為預先定義之對應數值，供模型識別與學習語法結構之用，完整對照表可見附錄表 A.1。



3.3.3 NLP 分析

為了取得更完整的語法資訊，本研究進一步採用 HanLP 工具套件進行自然語言處理分析，主要包含以下兩項語法結構擷取任務：

- **依存句法分析（Dependency Parsing [23]）**：用於判斷句子中各詞彙之間的依存關係，例如主詞與動詞、動詞與受詞之間的連結。透過依存樹結構，可以明確標示句子中語法角色的層級與方向，有助於掌握句子邏輯與語序安排。
- **成分句法分析（Constituency Parsing [4]）**：將句子視為由一系列語法片語（如名詞片語、動詞片語）組成，並建構出其樹狀結構。此分析可協助模型辨識語法片段的界線與層級，強化對句法結構的理解。

HanLP 為一款多語言、高效能的 NLP 開源套件，其支援繁體中文並內建多種深度學習模型，特別適合進行高階語法分析任務。在本系統中，所擷取之語法資訊（例如依存關係標籤與樹結構標記）可進一步作為輔助特徵輸入翻譯模型，提升模型在生成手語輸出時對語序與語義邏輯的掌握能力，前處理結果示意可見表 3.3。兩種句法分析對照表可見附錄表 B.1及表 B.2。

表 3.3: HanLP 前處理結果示意

處理項目	範例結果（輸入句：我喜歡學自然手語）
分詞（Tokens）	我、喜歡、學、自然、手語
依存句法分析 (Dependency Parsing)	
成分句法分析 (Constituency Parsing)	

3.4 模型架構

本研究的核心是利用預訓練語言模型進行中文至自然手語的翻譯。為了選出最適合本任務的基礎模型，並在此基礎上進行優化，我們首先對幾個主流的神經機器翻譯模型進行了深入的架構分析。本章將介紹本研究所評估與採用的模型，包括 MarianMT [10]、T5 [12] 與 mT5-Base [32]。此外，本節還會詳細說明我們最終選定 mT5-Base 模型後，所進行的結構修改與 Adapter 模組的整合方式。

3.4.1 MarianMT、T5 與 mT5 模型架構

本研究使用的 MarianMT、T5-Chinese 與 mT5-Base 模型皆屬於 Encoder-Decoder 結構之 Transformer 架構，整體設計高度一致。模型如圖 2.2 所示，皆包含編碼器（Encoder）與解碼器（Decoder）層，並在每層中由自注意力（Self-Attention）、前饋神經網路（Feed-Forward Network）以及層正規化（Layer Norm）等子結構所組成。雖然架構大致相同，各模型仍在層數設計、參數維度、位置編碼機制及詞彙表大小等方面存在差異，具體可見表 3.5。

表 3.4 為 mT5-Base 模型的結構描述。表中使用以下代號：

- **N**：Batch size
- **S**：輸入序列長度（Source sequence length）
- **T**：輸出序列長度（Target sequence length）
- **D**：隱藏層維度（T5/mT5-Base 為 768，MarianMT 為 512）
- **V**：詞彙表大小（mT5-Base 為 250112，T5-Chinese 為 32128，MarianMT 為 65001）

表 3.4: T5 模型架構

Layer Type	Input Shape	Output Shape
Shared Embedding	(N, S)	(N, S, D)
Encoder Embedding	(N, S)	(N, S, D)
Encoder (共 12 層)		
Self-Attention (每層)	(N, S, D)	(N, S, D)
Feed-Forward (每層)	(N, S, D)	(N, S, D)
Final Layer Norm (Encoder)	(N, S, D)	(N, S, D)
Decoder (共 12 層)		
Self-Attention (每層)	(N, T, D)	(N, T, D)
Cross-Attention (每層)	(N, T, D)	(N, T, D)
Feed-Forward (每層)	(N, T, D)	(N, T, D)
Final Layer Norm (Decoder)	(N, T, D)	(N, T, D)
LM Head	(N, T, D)	(N, T, V)

雖然 T5-Chinese 與 mT5-Base 均基於相同的模型架構，但兩者仍有以下差異，如表 3.5 所示。而 MarianMT 同樣具備 Encoder-Decoder 架構，但其模型維度與訓練策略更針對翻譯任務設計，與 T5 系列在實作細節上亦有所區別，例如使用正弦位置編碼（Sinusoidal Positional Encoding）與 SiLU 為啟動函數。

表 3.5: T5-Chinese、mT5-Base 與 MarianMT 模型架構比較

項目	T5-Chinese	mT5-Base	MarianMT
Encoder 層數	12	12	6
Decoder 層數	12	12	6
Hidden size (D)	768	768	512
FFN 中間維度	2048	2048	2048
詞彙表大小 (V)	32128	250112	65001
Positional Encoding	Learned	Learned	Sinusoidal
Activation Function	ReLU	ReLU	SiLU
訓練語料語言	中文	多語言	多語言
適用任務語言	中文	多語言泛用	多語翻譯任務

3.4.2 語言結構增強的模型設計

經過第 4.2.1 節的基礎模型比較實驗，結果顯示 mT5-Base 模型在本研究的中文至自然手語翻譯任務中展現了最佳的綜合性能。其多語言預訓練的背景使其在處理跨語言語法轉換時更具優勢。因此，本研究後續的優化與實驗皆基於 mT5-Base 模型進行。

為了進一步提升模型的翻譯品質，特別是強化其對中文語法結構的辨識能力與語序對齊效果，我們對 mT5-Base 的輸入階段進行了語言結構增強設計。此設計的核心思想是，除了原始的詞彙資訊 (Token Embedding)，額外將詞性 (Part-of-Speech, POS) 與依存句法關係 (Dependency Parsing, DEP) 作為額外資訊注入模型。

具體作法為：將每個輸入詞對應的詞性標記轉換為詞性索引 (POS IDs)，依存句法分析則轉換為對應的依附目標詞位 (Head Indices)，兩者分別嵌入為向量 (POS Embedding 與 DEP Embedding)。接著，將這些結構嵌入與原始 Token Embedding 融合，融合方式包含以下兩種策略：

- **加總方式 (Addition)**：將 Token Embedding、POS Embedding 與 DEP Embedding 逐元素相加，如圖 3.7 所示。
- **拼接方式 (Concatenation)**：將三者向量在特徵維度上進行串接，並使用線性變換將維度調整回模型輸入所需大小，如圖 3.8 所示。




圖 3.7: 加總方式 (Addition)：三種嵌入向量逐元素相加，不改變原始維度。




圖 3.8: 拼接方式 (Concatenation)：三種嵌入向量串接後經線性變換還原至模型原始輸入維度。

這樣的設計使模型在進入 Encoder 前，即可同時感知詞彙層次的語義與語法關係，強化語言理解能力。除嵌入層外，模型架構其他部分皆維持 mT5-Base 原有設計，詳見表 3.6。

表 3.6: 修改後 mT5-Base 模型架構（引入 POS 與 DEP 嵌入資訊）

層級類型 (Layer Type)	輸入維度 (Input Shape)	輸出維度 (Output Shape)
Token Embedding	(N, S)	(N, S, D)
POS Embedding (新增)	(N, S)	(N, S, D)
DEP Embedding (新增)	(N, S)	(N, S, D)
融合輸入 (加總或拼接)	—	(N, S, D')
Encoder (共 12 層)		
Self-Attention (每層)	(N, S, D')	(N, S, D')
Feed-Forward (每層)	(N, S, D')	(N, S, D')
Final Layer Norm (Encoder)	(N, S, D')	(N, S, D')
Decoder (共 12 層)		
Self-Attention (每層)	(N, T, D')	(N, T, D')
Cross-Attention (每層)	(N, T, D')	(N, T, D')
Feed-Forward (每層)	(N, T, D')	(N, T, D')
Final Layer Norm (Decoder)	(N, T, D')	(N, T, D')
LM Head	(N, T, D')	(N, T, V)

其中， N 為批次大小 (Batch size)， S 為輸入序列長度， T 為輸出序列長度， D 為原始 embedding 維度，而 D' 則視融合策略而定：若為加總則 $D' = D$ ，若為拼接則 $D' > D$ ，需透過線性轉換還原至原始維度。

3.4.3 基於 LoRA 的 Adapter 架構實作

為提升模型的微調效率，並使其能更專注地學習中文至自然手語的轉換模式，本研究採用了基於 LoRA 的 Adapter 架構。我們利用 Hugging Face 的 (PEFT Parameter-Efficient Fine-Tuning) 函式庫來實現此一機制，該函式庫提供了標準化且易於整合的 LoRA 實作。

基於第 2.2.5 節所介紹的 LoRA 原理，我們在後續的參數高效微調實

驗中，對 mT5-Base 與 mT5-Large 模型採用了相同的 LoRA 配置。其設定對應於程式碼中的 LoraConfig，具體如下：

1. **任務類型**：由於本研究的核心是翻譯任務，我們將任務類型設定為 SEQ_2_SEQ_LM，以適配 mT5 系列模型的序列到序列（Sequence-to-Sequence）架構。
2. **目標模組**：為了在不干擾模型大部分知識的前提下，精準調整其注意力機制，我們選擇將 LoRA 模組應用於模型 Encoder 中每一層 Self-Attention 的查詢（Query）與值（Value）投射層。這使得模型能夠在微調過程中學習如何針對手語翻譯任務，重新權衡輸入序列中不同詞語的重要性。此設定同時應用於 mT5-Base 和 mT5-Large 模型。
3. **核心超參數**：
 - **秩（Rank, r ）**：設為 16。此參數決定了低秩矩陣的規模，是效能與參數數量之間的權衡。
 - **縮放係數（Alpha, lora_alpha ）**：設為 16。此參數用於調整 LoRA 輸出結果的縮放比例，通常設為與 r 相同的值，以達到穩定的訓練效果。
 - **Dropout**：設為 0.1，以防止在訓練少量 LoRA 參數時發生過擬合。

透過此設計，本研究僅需訓練新增的低秩矩陣參數，而模型的數億個原始參數則保持凍結。此方法不僅大幅縮短了訓練時間、降低了硬體資源需求，也讓模型能在保有強大預訓練語言能力的基礎上，高效地適應與學習手語特有的語法及詞彙結構。

3.5 結構提示設計

為了提升模型對輸入句子的語法與語意理解，本研究將自然語言處理的結構資訊作為提示（Prompt）嵌入於輸入文本中。具體而言，將斷詞後的詞性（Part-of-Speech, POS）、依存句法分析（Dependency Parsing）、以及成分句法分析（Constituency Parsing）整合至原始輸入中，形成如下格式：

```

1  {
2      translate Chinese to Gloss: 我爸爸是聾人, 媽媽是聽人。
3      <POS> Nh Na SHI Na COMMACATEGORY Na SHI VE PERIODCATEGORY
4      <DEP> compound:nn nsubj cop root punct nsubj cop conj punct
5      <CON> TOP IP IP NP-SBJ NP Nh:我 NP Na:爸爸 VP SHI:是 NP-PRD
6      Na:聾人 COMMACATEGORY:, IP QP-SBJ Na:媽媽 VP SHI:是 NP-PRD
7      VE:聽人 PERIODCATEGORY:。
8  }
```

透過這種富含結構資訊的提示設計，我們預期能帶來以下效益：

- **強化語法對齊：**幫助模型更準確地將來源語言（中文）的語法結構對應到目標語言（手語）的獨特語法規則上。
- **提升語意理解：**使模型不僅學習詞彙的表面對應，更能理解其在句子中的功能與關係，從而生成語意更連貫、邏輯更清晰的翻譯。
- **改善長距離依賴：**顯性的句法連結有助於模型捕捉長句中的遠距離依賴關係，減少語意遺漏或錯亂。

總結來說，此方法將傳統上需要模型隱性學習的語法知識，轉化為明確的輸入信號，讓模型能夠在序列建模的基礎上，同時接收並利用語言的顯性結構資訊，最終提升中文至自然手語的翻譯品質與自然度。

3.6 後處理

本研究於模型生成後，進一步進行詞彙層級的後處理，主要目的是提升模型輸出語句與手語詞彙表的一致性，避免生成非手語中常見或習慣使用的詞彙。考量到語言模型可能輸出不在手語詞彙範圍內的詞彙，故本研究提出一套詞彙比對與替換機制，步驟如下：

1. **語意表示計算**：使用預訓練語意向量模型 text2vec-base-chinese [33] 將手語詞彙集轉換為向量，建立詞彙向量庫。
2. **自動組合詞替換**：為強化模型輸出與實際手語表達的一致性，優先參考教材資料集中預定義的組合手語對進行替換，確保術語與慣用語的一致表現，並降低語意偏移的風險。若無對應組合，則退而使用語意向量進行比對。具體的詞彙對應範例如表 3.7 所示，相關詞組定義參考自 [28]。
3. **相似詞搜尋**：針對模型輸出中不在詞彙庫內的詞，使用餘弦相似度 (*cosine similarity*) 計算其與手語詞彙庫的相似度，若相似度高於閾值（本研究設定為 0.8），則選擇最相近詞彙進行替換，具體公式可見式 3.1。

表 3.7: 自動組合詞替換示意

文本	教材資料集
組長	部分 + 長
答不出來	回答我 + 尷尬
意外事故	忽然 + 傷 + 死

$$\text{Similarity}(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \|\vec{b}\|} \quad (3.1)$$

其中， $\vec{a}$ 與 $\vec{b}$ 分別為輸出詞與詞彙庫詞彙的語意向量。

3.7 使用者介面

本研究設計一套整合圖形化介面（GUI）與後端處理流程的系統架構，如圖 3.9 所示。使用者透過 GUI 輸入欲轉換之句子，資料將透過後端傳送至前處理模組進行斷詞與 POS 標註後，交由模型進行手語書寫（Gloss）生成，經後處理模組整理後，回傳生成結果及相應手語影片予使用者，其具體介面如圖 3.10 所示。




圖 3.9: 本系統之整體架構。使用者透過 GUI 輸入文字，後端接收請求後依序執行前處理、模型推論及後處理，最終將翻譯結果與對應影片回傳至 GUI 顯示。




圖 3.10: 本系統之 GUI 介面。

四、實驗設計與結果

本章旨在驗證前述研究所提之方法，在臺灣手語書寫（Gloss）生成任務上的效能表現。所有實驗均基於第 3.1.1 節所述之手語與口語平行語料庫進行。為全面評估模型，本研究設計了由淺入深的系列實驗，並採用客觀的自動化指標進行量化分析。

4.1 實驗流程與評估指標

為系統性地探討各環節對模型效能的影響，整體實驗流程依序分為以下五個階段：

1. **基礎模型比較**：比較不同預訓練語言模型作為生成任務骨幹的表現，以選定最佳基準模型。
2. **語言特徵嵌入策略**：探討不同語言特徵嵌入（Embedding）方式對結果的影響。
3. **提示語設計（Prompting）**：分析不同提示語策略如何引導模型生成更準確的手語 Gloss。
4. **Adapter 導入評估**：評估引入 LoRA 適配器微調技術，在效能與訓練效率上的權衡與改善。
5. **資料擴增分析**：驗證資料擴增技術對於提升模型泛化能力的具體成效。

本章將依照上述步驟逐節呈現實驗結果與討論。為客觀評估模型輸出的品質，評估指標採用 BLEU 分數與 ROUGE 分數兩項常用的自動化文本評估指標，皆以分數越高代表翻譯與參考答案越接近，生成品質越佳。BLEU 強調 n-gram 精確度，適合衡量詞彙層級的重合程度；而 ROUGE 特別是 ROUGE-L，則強調長度與語序保留，能更完整地評估句子層次的語意對齊表現，其詳細計算方式可見第 2.2.6 節與第 2.2.7 節。

4.2 實驗環境與參數設定

本研究所有實驗均在統一的环境下進行，以確保結果的可比較性與重現性。資料集依照 80% 與 20% 的比例，隨機劃分為訓練集與測試集。詳細的硬體資源與模型訓練參數設定如下：

- 運算資源：NVIDIA GeForce RTX 4060 Ti 16GB $\times$ 2
- 損失函數：Cross Entropy Loss
- 優化器：AdamW
- 初始學習率： 5×10^{-5}
- 訓練週期數 (Epochs)：40
- 批次大小 (Batch Size)：2
- 學習率調整策略：線性預熱 (Linear Warmup)，預熱步數設為 100
- 權重衰減 (Weight Decay)：0.01

4.2.1 不同模型結果

本節將比較不同基礎模型在本研究資料集上的表現，藉此選定後續實驗的主要模型。評估對象涵蓋三種 Transformer 系列的中文翻譯預訓練模型：**MarianMT**、**T5-Chinese** 與 **mT5-Base**，以及作為對照組的 **ChatGPT** 模型。所有模型均使用相同的訓練資料與評估標準進行比較。

其中，ChatGPT 模型採用系統角色設定（System Prompt）進行控制，指定其模擬手語翻譯工具的角色，輸出臺灣自然手語（Taiwan Sign Language, TSL）之 Gloss 表示形式。生成內容以空白鍵分隔每個詞彙，省略語助詞與書面語標點，並聚焦於保留語意核心。其 Prompt 設計如下所示：

```

1      {
2          role="system",
3          content=
4              "你現在是一個翻譯工具，負責將中文句子翻譯為台灣自然手語
5              （Taiwan Sign Language, TSL）的 gloss 形式。
6              請用空白鍵分隔每個手語詞彙。
7              忽略語助詞與書面語標點，並優先保留語意核心。
8              範例：
9              輸入：你住在板橋還是新莊？
10             輸出：你 住 板橋 新莊 哪裡 "
11     }
```

ChatGPT 實驗設定：Prompt 設計範例

各模型在本研究資料集上的 BLEU 與 ROUGE-L 評分如表 4.1 所示：

表 4.1: 不同基礎模型在資料集上的效能對比*

模型	訓練集 (Training Set)					測試集 (Test Set)				
	BLEU				ROUGE-L (F1)	BLEU				ROUGE-L (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		BLEU-1	BLEU-2	BLEU-3	BLEU-4	
MarianMT	47.12	34.53	25.11	19.85	0.5133	36.84	21.34	14.98	12.97	0.4079
T5-Chinese	47.88	34.21	25.94	20.52	0.5260	37.59	21.86	15.37	13.43	0.4104
mT5-Base	48.55	35.12	26.01	20.98	0.5411	34.19	23.22	16.84	14.16	0.4362
ChatGPT	N/A	N/A	N/A	N/A	N/A	33.05	19.03	13.13	10.50	0.3821

*ChatGPT 以 Zero-shot 方式進行評估，無獨立的訓練過程，故不提供訓練集分數。

從實驗結果可觀察到，**mT5-Base 在所有 BLEU 與 ROUGE-L 評分項目中皆取得最高分數**，顯示其在手語書寫生成任務中具備最佳表現。mT5-Base 為多語言版本的 T5，具備處理跨語言語料的能力，對於中華語系手語 Gloss 表示的生成任務而言更具彈性與語意捕捉能力。相較之下，ChatGPT 雖具備優秀的語言生成能力，但在未經 Fine-Tune 的前提下，其生成風格與研究任務需求仍存在落差。需要特別說明的是，**ChatGPT 模型並未經過任何手語資料的微調或額外訓練**，本實驗僅透過提示詞（Prompt）進行控制，屬於典型的 **Zero-Shot** 應用場景。也就是說，模型在完全未見過訓練資料的情況下，僅根據語意理解與推理能力產生輸出。此設定主要作為對照組，評估目前大型語言模型在未經專門訓練下對手語 Gloss 生成的初始表現，亦可用以檢視微調模型的增益空間。

綜合評估後，本研究將選擇 **mT5-Base** 作為後續實驗與改良的主要模型架構。

4.2.2 不同 Embedding 方式比較

為驗證語言結構資訊（POS 與 DEP）嵌入方式對模型效能之影響，本節設計三種實驗組別進行比較：

- **Baseline**：未引入任何結構資訊，僅使用原始 Token Embedding 作為輸入。
- **Add（加總方式）**：將 Token Embedding、POS Embedding 與 DEP Embedding 逐元素相加，作為 Encoder 輸入。
- **Concat（拼接方式）**：將三種嵌入向量於特徵維度上串接後，經由線性投影壓回模型輸入維度，再送入 Encoder。

實驗結果如表 4.2 所示，評估指標包括 BLEU-1 至 BLEU-4，以及 ROUGE F1 分數。

表 4.2: 不同 Embedding 融合方式對模型效能之影響

Embedding 方式	訓練集 (Training Set)					測試集 (Test Set)				
	BLEU				ROUGE (F1)	BLEU				ROUGE (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		BLEU-1	BLEU-2	BLEU-3	BLEU-4	
Baseline	48.55	35.12	26.01	20.98	0.5411	34.19	23.22	16.84	14.16	0.4362
Add	47.91	34.05	25.12	19.89	0.5280	37.84	22.38	15.65	13.20	0.4221
Concat	6.12	3.01	1.55	1.32	0.0805	5.64	2.89	1.34	1.19	0.0713

由實驗可觀察到：

- 加總方式（Add）雖整體效能略低於 Baseline，但差距不大，顯示語言結構資訊以此方式融合時，對模型表現影響有限。
- 拼接方式（Concat）則導致模型效能大幅下降，推測可能與向量維度增加後的投影過程造成訊息混雜或訓練不穩定有關。

整體而言，直接引入語法結構資訊未必能顯著提升表現，提示語設計或模組插入策略可能更為關鍵。本研究後續將聚焦於提示語融合與 Adapter 架構的搭配探討。

4.2.3 不同 Prompt 方式比較

為評估不同語言特徵提示 (Prompt) 對模型效能的影響，本研究測試了多種組合，包括詞性 (POS)、依存句法 (DEP)、成分句法 (CON) 三種資訊，以及其不同組合形式。表 4.3 彙整了各組合在 BLEU-1 至 BLEU-4 及 ROUGE 指標上的表現。

表 4.3: 不同 Prompt 組合在訓練集與測試集上的效能表現

Prompt 組合	訓練集 (Training Set)					測試集 (Test Set)				
	BLEU				ROUGE (F1)	BLEU				ROUGE (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		BLEU-1	BLEU-2	BLEU-3	BLEU-4	
無 Prompt (Baseline)	48.55	35.12	26.01	20.98	0.5411	34.19	22.02	15.94	12.86	0.4362
POS	49.21	36.98	27.15	21.03	0.5595	35.09	21.50	14.87	11.57	0.4256
DEP	50.88	38.11	28.99	22.15	0.5688	36.20	22.99	17.46	13.63	0.4341
CON	51.05	37.55	27.99	22.40	0.5701	36.14	22.51	17.07	13.73	0.4290
POS + DEP	53.91	40.15	30.02	23.18	0.5985	38.25	24.47	18.72	15.02	0.4361
POS + CON	53.15	39.02	28.76	22.54	0.5824	39.51	24.35	18.16	14.74	0.4420
DEP + CON	53.22	41.30	31.05	23.99	0.5950	40.13	25.09	18.66	14.51	0.4491
POS + DEP + CON	54.10	42.01	31.88	24.55	0.6012	41.34	25.37	17.86	14.50	0.4605

由表 4.3 可觀察到，不同的語言特徵提示對模型效能具有顯著影響。整體而言，加入 Prompt 能夠有效提升翻譯品質，尤以結合多種語言資訊的組合表現最為理想。其中，結合 **POS + DEP + CON** 的組合在 BLEU-1 (41.34)、BLEU-2 (25.37) 及 ROUGE-L (46.05) 皆達到最佳表現，顯示多層次語言提示可為模型提供更完整的語法與語意資訊，進而提升語言生成品質。

若以 n-gram 的長度進一步分析，**POS + DEP** 組合在 BLEU-3 (19.72) 與 BLEU-4 (15.42) 上表現最優，顯示該組合對長距依存關係的建模特

別有效，能增進語句結構的一致性。

相較之下，單一提示（如 POS、DEP 或 CON）所帶來的效能提升較為有限，甚至在某些指標（如 BLEU-1）略低於 Baseline，可能是因為單一語言資訊無法充分捕捉句子中的語意與語法複雜性。然而，這些特徵在進行多特徵融合時仍展現出輔助效果。

綜上所述，本研究結果顯示融合多種語言結構提示為提升翻譯效能的可行策略，建議後續系統設計中採用多提示融合方式，並進一步探討提示嵌入形式與位置對模型學習效果之影響。

4.2.4 Adapter 架構添加比較

為探討在資源受限的條件下，如何在模型效能與訓練效率之間取得平衡，本研究對參數高效微調技術 LoRA（Low-Rank Adaptation）[34] 進行了深入評估。實驗設計聚焦於以下兩個核心問題：

- 在相同的基礎模型（mT5-Base）下，LoRA 微調與全參數微調（Full Fine-tuning）在效能與效率上有何差異？
- 使用 LoRA 微調更大規模的模型（mT5-Large），是否能在較低資源成本下，達到或超越小模型的全參數微調效能？

為回答上述問題，本研究設計了三組實驗，並在一致的輸入設計（POS + DEP + CON）下進行訓練比較：

- **mT5-Base (Full-tuning)**：作為效能基準（Baseline），對 mT5-Base 的全部 5.8 億參數進行全參數微調。
- **mT5-Base (LoRA)**：在 mT5-Base 架構中應用 LoRA，僅微調約 177 萬個額外參數。
- **mT5-Large (LoRA)**：對更大規模的 mT5-Large（12 億參數）應用 LoRA。由於 mT5-Large 無法進行全參數微調（因 OOM），此實驗

旨在探討 LoRA 是否可作為啟用大模型潛力的可行方案。

4.2.4.1 模型效能分析

從效能結果(表 4.4)可見，**mT5-Base (LoRA)** 雖在 BLEU 與 ROUGE-L 指標上略遜於全參數微調的 Baseline，這符合僅更新 0.3% 參數的預期。但更值得注意的是，**mT5-Large (LoRA)** 雖然僅訓練 0.38% 的參數，卻在 BLEU-2、BLEU-3 與 BLEU-4 等衡量句子流暢度的指標上，已非常接近甚至超越 mT5-Base (Full-tuning)。此結果強化了 LoRA 能以極小的訓練代價，充分發揮大模型語言理解與生成能力的潛力。

表 4.4: 不同微調策略下的模型效能表現比較

模型設定	訓練集 (Training Set)					測試集 (Test Set)				
	BLEU				ROUGE-L (F1)	BLEU				ROUGE-L (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		BLEU-1	BLEU-2	BLEU-3	BLEU-4	
mT5-Base (Full-tuning)	54.10	42.01	31.88	24.55	0.6012	41.34	25.37	17.86	14.50	0.4605
mT5-Base (LoRA)	42.74	27.56	24.77	18.10	0.4873	35.95	22.89	16.78	13.23	0.4078
mT5-Large (LoRA)	52.93	39.67	28.80	23.91	0.5740	40.41	26.02	17.57	14.42	0.4536

4.2.4.2 訓練效率與底層計算分析

在訓練效率方面，LoRA 的優勢更為顯著(表 4.5)。在 mT5-Base 模型上，LoRA 將可訓練參數數量從 5.8 億大幅下降至約 177 萬(減少 99.7%)，峰值 VRAM 使用量也降低了約 45%。更重要的是，LoRA 使得更大規模的模型訓練成為可能。全參數微調 12 億的 mT5-Large 模型會因記憶體不足而失敗，但採用 LoRA 後，不僅能順利訓練，其峰值 VRAM 使用量(~15.28 GB)甚至與全參數微調 mT5-Base(~14.65 GB)相近。

表 4.5: 不同微調策略的模型訓練效率比較

模型設定	可訓練參數數量 (%)	單 GPU 峰值 VRAM	訓練時間 (分鐘)
mT5-Base (Full-tuning)	584,156,928 (100%)	~14.65 GB	165.75
mT5-Base (LoRA)	1,769,472 (0.3%)	~8.13 GB	114.86
mT5-Large (Full-tuning)	1,234,281,472 (100%)	OOM	—
mT5-Large (LoRA)	4,718,592 (0.38%)	~15.28 GB	218.02

註：VRAM 使用量為在 2x RTX 4060 Ti (16GB) 訓練環境下的單張 GPU 峰值。OOM 表示記憶體不足。

為了探究訓練時間差異的底層原因，我們利用 PyTorch Profiler 對單次訓練疊代 (iteration) 中的關鍵計算環節進行了量化分析 (表 4.6)。數據顯示，訓練時間主要由必須遍歷整個網路的前向傳播 (Forward Pass) 和反向傳播 (Backward Pass) 決定。

值得注意的是，mT5-Base (LoRA) 的前向傳播平均耗時 (72.63 ms) 反而高於全參數微調的版本 (55.82 ms)。這是因為 LoRA 的運作機制是在凍結的原有權重旁，額外增加了可訓練的低秩矩陣 (A 和 B) 進行旁路計算。因此，在前向傳播過程中，計算流不僅要通過原始的凍結層，還需執行這個額外的矩陣乘法運算 ($h' = h + B \cdot A \cdot x$)，從而導致了計算量的微幅增加。

儘管如此，LoRA 的整體時間效率優勢依然顯著，這主要源於權重更新 (Optimizer Step) 環節的大幅優化。在 mT5-Base (Full-tuning) 中，由於優化器需為 5.8 億參數維護狀態，此步驟佔用了高達 33.16% 的時間；而在 LoRA 中，該佔比驟降至 12.23%。這也解釋了為何 LoRA 參數量的巨幅減少並未帶來同等比例的訓練時間縮短，因為計算瓶頸仍在於前向與反向傳播。

表 4.6: 訓練疊代中各計算環節的時間佔比分析

計算環節	平均耗時 (ms/step)			時間佔比 (%)		
	Base (Full)	Base (LoRA)	Large (LoRA)	Base (Full)	Base (LoRA)	Large (LoRA)
Forward Pass	55.82	72.63	176.03	22.95%	35.91%	41.91%
Backward Pass	106.73	104.91	204.37	43.88%	51.86%	48.66%
Optimizer Step	80.66	24.73	39.61	33.16%	12.23%	9.43%
總計	243.21	202.27	420.01	100%	100%	100%

綜合來看，LoRA 在顯著降低訓練成本與資源需求的同時，仍可維持具競爭力的表現。雖然其效能略低於全參數微調，但透過應用於大模型，其潛力反而得以充分發揮。LoRA 因此提供了一個靈活、高效且實用的微調策略，特別適合於快速原型開發、反覆實驗設計，或在硬體資源受限的情境中部署大型語言模型。

4.2.5 擴增資料集比較

為應對本研究中平行語料數量有限的挑戰，我們採用了資料擴增策略（詳見第 3.3.1 節）以提升模型的泛化能力。本節旨在量化並驗證此策略的實際成效。

為直接評估此策略的影響，圖 4.1 直觀地對比了模型在擴增前後，於各 Prompt 組合下的測試集效能。數據揭示了一個關鍵的交互作用：當模型結合語言學提示（Prompt）時，資料擴增策略展現出顯著且一致的正面效益。在所有包含 POS、DEP 或 CON 的組合中，擴增後的模型在各項 BLEU 與 ROUGE-F1 指標上均獲得了穩固的提升。

然而，在「無提示（No Prompt）」的基準設定下，擴增後的模型在 BLEU 分數上出現了輕微的衰退。此現象並不意味著擴增無效，反而可能揭示了，當數據的句法多樣性增加後，若缺乏明確的語法結構引導，模型在生成精確 n-gram 方面的穩定性會面臨挑戰。這一發現也從反面印證了本研究提出的 Prompt 設計，在協助模型駕馭複雜語料時的關鍵作用。總體而言，實驗結果證明了資料擴增與語言學提示之間存在重要的互補關係。

表 4.7 進一步呈現了在擴增資料集的基礎上，各 Prompt 組合的詳細評估數據。分析此表可得出以下核心結論：

- 語言學提示與資料擴增的互補效應：在更豐富的資料基礎上，語言學提示的正面效益依然顯著。所有加入 Prompt 的模型均優於「無 Prompt」的基線模型。其中，「POS + DEP + CON」的組合再次脫穎而出，在測試集上取得了 18.00 的 BLEU-4 分數與 0.4881 的 ROUGE-F1 分數，成為表現最佳的模型。這表明，資料擴增為模型提供了更穩固的學習基礎，使其能更充分地利用 Prompt 提供的精細化語法資訊。
- 泛化能力的提升：對比擴增前後的數據（如圖 4.1 所示），模型在

BLEU-1 至 BLEU-4 各指標上普遍獲得了 2 至 5 個百分點的增長。此一穩定的性能提升，證實了資料擴增是解決低資源場景下數據稀疏問題、強化模型泛化能力的有效手段。

綜上所述，本節實驗清晰地論證了資料擴增策略的必要性與有效性。它不僅全面提升了模型的基準性能，更與本研究提出的語言學提示方法形成了良好的互補關係。

表 4.7: 擴增資料集後，不同 Prompt 組合在訓練集與測試集上的效能表現

Prompt 組合	訓練集 (Training Set)					測試集 (Test Set)				
	BLEU				ROUGE (F1)	BLEU				ROUGE (F1)
	BLEU-1	BLEU-2	BLEU-3	BLEU-4		BLEU-1	BLEU-2	BLEU-3	BLEU-4	
無 Prompt (Baseline)	50.32	37.84	28.06	22.64	0.5622	36.89	22.72	16.34	13.19	0.4412
POS	53.84	40.28	30.41	23.69	0.4689	39.41	24.56	17.80	13.60	0.4689
DEP	52.91	39.43	29.76	22.97	0.5795	40.49	26.30	19.33	15.76	0.4703
CON	53.07	38.82	28.98	23.32	0.5867	40.54	25.66	19.49	15.98	0.4636
POS + DEP	55.86	41.79	31.56	24.08	0.6103	41.83	27.52	20.69	17.13	0.4764
POS + CON	54.98	40.45	29.97	23.15	0.5915	40.72	27.25	20.53	16.87	0.4704
DEP + CON	56.45	43.04	32.45	24.96	0.6048	41.00	26.09	19.90	15.68	0.4804
POS + DEP + CON	57.00	43.36	33.04	25.38	0.6148	42.72	29.61	22.36	18.00	0.4881




圖 4.1: 擴增資料集前後測試集分數對比

4.3 結果呈現與分析

本研究成功實作了一套圖形化使用者介面（GUI），能將中文句子轉換為手語書寫符號（Gloss），並同步生成對應手語影片，作為視覺輔助。此介面整合了句子輸入、語言提示（Prompt）選擇、模型翻譯輸出與影片播放四大核心功能，提供一套完整且流暢的操作流程。

圖 4.2 展示了本系統的核心操作介面，整體設計直觀，可分為以下四大功能區塊：

- **輸入區塊**：使用者可在此輸入欲翻譯的中文句子，並整合了語音輸入功能，提升操作的便捷性。
- **Prompt 組合選項**：提供詞性（POS）、依存句法（DEP）與成分句法（CON）等語言學提示選項，用以豐富輸入的語言結構特徵，引導模型進行更精準的語意理解。
- **模型輸出區**：即時顯示模型預測的 Gloss 結果，並一併呈現所選用的 Prompt 資訊，方便使用者比對分析。
- **手語影片展示區**：根據輸出的 Gloss 序列，自動播放對應的手語影片，便於使用者進行即時的視覺化比對與確認，其中影片來源自第 3.1.2 節之手語辭彙資料集。

4.3.1 模型效能驗證

本節針對本系統於不同句型（含短句與長句）之翻譯表現進行驗證，觀察其在語句結構與語意重組上的準確性與穩定性。

首先，在簡短問句的測試中（表 4.8），本系統展現了超越逐字翻譯的語意理解能力。對於輸入的「你結婚了嗎？」，其斷詞結果為你/結婚/了/嗎/?。然而，模型並非機械地對應這些詞彙，而是成功地將其重組

為符合臺灣手語語法的結婚/完了? (疑問表情)。此結果顯示，模型能省略在手語中非必要的主語你，並將時態助詞了與疑問詞嗎整合為手語中表完成與疑問的完了? (疑問表情)，證明其具備了基礎的跨語言語法轉換能力。




圖 4.2: GUI 結果展示 1

表 4.8: 模型輸出比對 1

文本	你結婚了嗎?
斷詞結果	你/結婚/了/嗎/?
模型輸出	結婚/完了? (疑問表情)
正確輸出	結婚/完了? (疑問表情)

中等長度語句的測試（表 4.9）亦顯示模型能準確轉換語句，並結合語言提示進行輔助。如圖 4.3 所示，使用者可選擇不同的 Prompt 組合進行翻譯，增加語言結構的辨識度。




圖 4.3: GUI 結果展示 2，可選擇各種 Prompt 組合，圖為選擇了 DEP 與 CON 組合進行輸入的結果

表 4.9: 模型輸出比對 2

文本	大家上課要準時
斷詞結果	大家/上課/要/準時
模型輸出	大家/上課/準時/要//
正確輸出	大家/上課/準時/要//

系統亦展現處理長句與複合句的能力。圖 4.4 與圖 4.5 所對應之表 4.10 與 4.11，皆顯示模型能完整保留語句核心資訊，並將原句重組為符合手語語法之 Gloss 序列，展現良好的長距語言建模能力。

以表 4.11 為例，面對包含兩個子句的複雜輸入，模型並未受中文在、從... 到等介詞結構的束縛。它成功地從冗長的斷詞序列中提取出「爸爸-新竹-工作」與「家-臺北-開車-二小時」這兩個核心語意區塊，並將其重組為符合手語主題評論（Topic-Comment）結構的 Gloss 序列。這證明本研究提出的方法在處理長距離依賴關係與跨語言語法結構轉換上具有顯著成效。




圖 4.4: GUI 結果展示 3，長句輸出結果，模型也能正確輸出轉換後的結果

表 4.10: 模型輸出比對 3

文本	電視一直宣導: 要小心詐騙集團。
斷詞結果	電視/一直/宣導/要/小心/詐騙/集團/。
模型輸出	電視/宣佈/詐騙/注意/要//
正確輸出	電視/宣佈/詐騙/注意/要//




圖 4.5: GUI 結果展示 4, 長句輸出結果

表 4.11: 模型輸出比對 4

文本	我爸爸在新竹上班, 家住臺北, 從臺北開車到新竹要二個小時。
斷詞結果	我/爸爸/在/新竹/上班/, /家/住/臺北/, /從/臺北/開車/到/新竹/要/二/個/小時/。
模型輸出	爸爸/新竹/工作//家/臺北/開車/二個小時//
正確輸出	爸爸/新竹/工作//家/臺北/開車/二個小時//

綜上所述，本系統能穩定處理不同長度與結構的中文語句，且翻譯結果在語序、語意及手語邏輯上皆具有一定正確性，顯示所建模的語言提示與語法理解具實質成效。

4.3.2 錯誤案例分析

儘管整體表現良好，模型在某些語句結構上仍可能產生錯誤。圖 4.6 呈現一個典型案例：系統未能正確理解「可選擇去英國或是法國」的語意邏輯，導致生成結果詞彙重複、語法不自然。




圖 4.6: 錯誤輸出結果

表 4.12: 模型輸出比對 5

文本	公司的旅遊活動, 你可選擇去英國或是法國
斷詞結果	公司/的/旅遊/活動/,/你/可/選擇/去/英國/或是/法國
模型輸出	公司/旅行/活動/你/選擇/英國/法國/選擇/可以//
正確輸出	公司/旅行/玩//英國/法國/這兩個/二選一//

為了更清晰地對比，表 4.12 將模型的輸出與正確的手語 Gloss 進行了並列呈現。從表中可見，模型輸出「公司/旅行/活動/你/選擇/英國/法國/選擇/可以//」雖然保留了核心關鍵詞，但出現了詞語重複（選擇）且語法結構不自然的問題。相較之下，正確的輸出「公司/旅行/玩//英國/法國/這兩個/二選一//」則更貼近自然手語的表達方式，語意清晰且流暢。

首先，模型可能過度依賴來源語言（中文）的詞序，傾向於進行逐字對應的「表面翻譯」，而非真正理解後的「語意轉譯」。從輸出結果可見，模型將中文的「可選擇」拆解為選擇和可以兩個獨立的 Gloss，卻未能將其組合成符合手語語法的單一概念。同時，重複出現的選擇一詞，也反映出模型在生成序列時，可能因上下文關聯性而產生統計性錯誤，而非基於對整體句意的理解。

其次，模型對於手語中特定的語法構式掌握不足。自然手語在表達「A 或 B」的選擇概念時，常使用「A/B/這兩個/二選一//」這樣的空間性或分類性語法。模型的輸出結果顯示，它未能學習到此一模式，僅是單純地將選項英國/法國並列。此類錯誤凸顯了模型在捕捉目標語言獨特語法結構上仍有優化空間，特別是當目標語言的表達邏輯與來源語言存在顯著差異時。

4.3.2.1 針對性資料增強與再訓練

為了解決上述特定句型的翻譯問題，本研究採取了針對性資料增強（Targeted Data Augmentation）的策略。我們額外蒐集並標註了 25 筆包含

「A 或 B」選擇性語意的中文與手語 Gloss 對應資料，並將其加入原始訓練集中，對模型進行再訓練。表 4.13 與圖 4.7 分別展示了再訓練後，模型對於同一樣本句子在 Gloss 層面與 GUI 視覺層面的輸出結果。

表 4.13: 再訓練後模型輸出比對

文本	公司的旅遊活動, 你可選擇去英國或是法國
原始模型輸出	公司/旅行/活動/你/選擇/英國/法國/選擇/可以//
再訓練後輸出	公司/旅行/玩//英國/法國/這兩個/二選一//




圖 4.7: 再訓練後模型正確輸出 GUI 介面展示

如表 4.13 與圖 4.7 所示，經過再訓練的模型成功學習到手語處理選擇概念的特定語法模式。新的輸出結果不僅避免了詞彙重複的問題，更重

要的是，它準確地採用了「這兩個/二選一」的分類式語法，生成了語意清晰且符合手語母語者習慣的自然表達。此結果驗證了針對性地擴增特定語法結構的訓練資料，是改善模型在特定句型上表現的有效策略，能顯著提升翻譯的準確性與自然度。

綜合而言，本研究開發的 GUI 結合直覺操作與即時視覺回饋，讓使用者能快速輸入、調整參數並觀看結果。此設計大幅提升易用性與互動性，對手語學習者、研究人員與聽障者皆為實用高效的輔助工具。未來，本系統具良好擴充潛力，可應用於語言教育、即時溝通與無障礙資訊服務等多元情境中。

五、 總結

5.1 結論

本研究針對中文轉換為手語書寫（Sign Language Gloss）任務，提出一套結合 Transformer 架構與自然語言處理（NLP）輔助輸入的手語生成模型，並透過一系列實驗驗證其成效。在模型設計上，以多語預訓練模型 mT5-Base 為基礎，結合詞性標註、依存句法分析與成分句法分析等語法特徵作為提示，強化模型在語句層級的結構理解與對齊能力。

在訓練策略方面，本研究探討了參數高效微調技術。首先，在 mT5-Base 模型上，導入低秩適應技術 LoRA 雖大幅降低了訓練資源需求，但在 BLEU 與 ROUGE 分數上未能超越完整微調模型，顯示其在效率與效能間存在權衡。然而，本研究進一步發現，利用 LoRA 微調更大規模的 mT5-Large 模型，能在與完整微調 mT5-Base 相近的硬體資源下，達到具備高度競爭力的翻譯表現。這一結果凸顯了 LoRA 作為一種「以低成本釋放大模型潛力」的實用策略，在資源受限的場景下極具價值。

針對低資源資料問題，本研究亦設計資料擴增策略，包括長句切分與語意近詞替換，有效提升資料多樣性與模型泛化能力。實驗結果顯示，資料擴增後的模型整體表現皆優於原始資料訓練結果，證實擴增策略的實用性。

綜合而言，本研究成功整合語言學特徵與深度學習架構，實作出一套具可擴充性與語法敏感度的中文手語轉換模型，為未來人機溝通輔助、聽障者語言科技應用提供重要技術參考與基礎。

5.2 未來展望

本研究針對中文轉手語書寫之任務，整合多項自然語言處理技術與預訓練語言模型，初步驗證了語言結構提示（POS、DEP、CON）對模型生成品質之助益。基於本研究成果，後續可朝以下幾個方向進行擴展與深入探討：

1. **跨模態生成與評估機制**：本研究目前聚焦於文字轉文字的生成任務，未涵蓋手語實際表現（Sign Performance）階段。未來可結合影像生成或手部動畫模組，實作從中文至完整手語動畫的轉換流程，並建立專門針對手語評估的客觀與主觀指標，提升應用層面可行性。
2. **低資源語言與擴增方法優化**：針對資料稀缺問題，後續可導入自動資料擴增（如 Back-Translation、Paraphrasing）、語言模型生成語料，以提升模型在資源受限場景下之效能。
3. **模型架構與訓練策略改良**：雖然本研究初步導入 LoRA 輕量化適應技術，仍有進一步優化空間。未來可考慮更先進的 Adapter 架構（如 Prefix Tuning、IA³ 等），或多任務學習（Multi-task Learning）方式，同時學習語義分析與手語生成，以促進語言理解與輸出品質的同步提升。
4. **應用於溝通輔具與教育場景**：本研究模型可進一步整合於手語教學系統、即時口譯輔助工具或數位學習平台中，協助聽障者與聽人族群在教育、醫療、職場等情境中溝通更加順暢，促進資訊平權與社會參與。

綜上所述，中文轉手語生成仍為一項具挑戰但極具潛力之研究課題。未來透過更細緻之語言建模、跨模態融合與實用場景應用，將能進一步提升系統效能與實際價值，為聽障者語言科技發展奠定更堅實的基礎。

參考文獻

- [1] 衛生福利部. “身心障礙者人數按等級及類別分.” Accessed: May 12, 2025. [Online]. Available: <https://www.mohw.gov.tw/dl-69414-ee6c345a-38a4-4851-9c0d-28b8c0fd3948.html>.
- [2] 中華民國啟聰協會. “台灣手語介紹及手語 QA.” Accessed: May 12, 2025. [Online]. Available: <https://www.deaf.org.tw/OnePage.aspx?mid=51&id=46>.
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” 2017, *arXiv:1706.03762*.
- [4] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*, 3rd. 2025, Online manuscript released January 12, 2025. [Online]. Available: <https://web.stanford.edu/~jurafsky/slp3/>.
- [5] CKIPLab. “ckiplab/ckip-transformers: Transformer-based Chinese NLP models by CKIP.” Accessed: May 12, 2025. [Online]. Available: <https://github.com/ckiplab/ckip-transformers>.
- [6] H. He and J. D. Choi, “The Stem Cell Hypothesis: Dilemma behind Multi-Task Learning with Transformer Encoders,” in *Proc. 2021 Conf. Empirical Methods Natural Lang. Process.*, Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, Nov. 2021, pp. 5555–5577. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.451>.
- [7] I. Sutskever, O. Vinyals, and Q. V. Le, “Sequence to sequence learning with neural networks,” in *Proc. 28th Int. Conf. Neural Inf. Process. Syst. - Vol. 2*, Cambridge, MA, USA: MIT Press, 2014, pp. 3104–3112.
- [8] D. Bahdanau, K. Cho, and Y. Bengio, “Neural Machine Translation by Jointly Learning to Align and Translate,” 2016, *arXiv:1409.0473*.
- [9] M.-T. Luong, H. Pham, and C. D. Manning, “Effective Approaches to Attention-based Neural Machine Translation,” 2015, *arXiv:1508.04025*.
- [10] M. Junczys-Dowmunt et al., “Marian: Fast Neural Machine Translation in C++,” 2018, *arXiv:1804.00344*.

- [11] Y. Liu, J. Gu, N. Goyal, X. Li, S. Edunov, M. Ghazvininejad, M. Lewis, and L. Zettlemoyer, “Multilingual Denoising Pre-training for Neural Machine Translation,” 2020, *arXiv:2001.08210*.
- [12] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” 2019, *arXiv:1910.10683*.
- [13] Y. Ouargani and N. E. Khattabi, “Advancing Text-to-GLOSS Neural Translation Using a Novel Hyper-parameter Optimization Technique,” 2023, *arXiv:2309.02162*.
- [14] S. Egea Gómez, E. McGill, and H. Saggion, “Syntax-aware Transformers for Neural Machine Translation: The Case of Text to Sign Gloss Translation,” in *Proc. 14th Workshop Building and Using Comparable Corpora (BUCC 2021)*, R. Rapp, S. Sharoff, and P. Zweigenbaum, Eds., Online (Virtual Mode): INCOMA Ltd., Sep. 2021, pp. 18–27. [Online]. Available: <https://aclanthology.org/2021.bucc-1.4/>.
- [15] D. Zhu, V. Czehmann, and E. Avramidis, “Neural Machine Translation Methods for Translating Text to Sign Language Glosses,” in *Proc. 61st Annu. Meeting Assoc. Comput. Linguistics (Volume 1: Long Papers)*, A. Rogers, J. Boyd-Graber, and N. Okazaki, Eds., Toronto, Canada: Association for Computational Linguistics, Jul. 2023, pp. 12 523–12 541. doi: 10.18653/v1/2023.acl-long.700. [Online]. Available: <https://aclanthology.org/2023.acl-long.700/>.
- [16] S. M. Abdullah, A. Paul, S. Rayana, A. Kabir, and Z. Masud, “State-of-the-Art Translation of Text-to-Gloss using mBART: A case study of Bangla,” 2025, *arXiv:2504.02293*.
- [17] N. C. Camgoz, S. Hadfield, O. Koller, H. Ney, and R. Bowden, “Neural Sign Language Translation,” in *Proc. 2018 IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 7784–7793. doi: 10.1109/CVPR.2018.00812.
- [18] T. Hanke, M. Schulder, R. Konrad, and E. Jahn, “Extending the Public DGS Corpus in Size and Depth,” in *Proc. LREC2020 9th Workshop Representation and Process. Sign Lang.*, Marseille, France: European Language Resources Association (ELRA), May 2020, pp. 75–82. [Online]. Available: <https://aclanthology.org/2020.signlang-1.12/>.
- [19] R. Konrad et al., *MEINE DGS – annotiert. Öffentliches Korpus der Deutschen Gebärdensprache, 3. Release / MY DGS – annotated. Public Corpus of German Sign Language, 3rd release*, Version 3.0, 2020. doi: 10.25592/dgs.corpus-3.0. [Online]. Available: <https://doi.org/10.25592/dgs.corpus-3.0>.
- [20] SignTube. “台灣手語南北差異 2.” Accessed: May 12, 2025. [Online]. Available: https://www.youtube.com/shorts/_qzWN4ZCYTA.
- [21] 立法院. “國家語言發展法.” Accessed: May 12, 2025. [Online]. Available: <https://law.moj.gov.tw/LawClass/LawAll.aspx?pcode=H0170143>.

- [22] K. Toutanova, D. Klein, C. D. Manning, and Y. Singer, “Feature-rich part-of-speech tagging with a cyclic dependency network,” in *Proc. 2003 Conf. North Amer. Chapter Assoc. Comput. Linguistics on Human Lang. Technol.*, Association for Computational Linguistics, 2003, pp. 173–180.
- [23] S. Kübler, R. McDonald, and J. Nivre, *Dependency Parsing*. San Rafael, CA, USA: Morgan & Claypool Publishers, 2009.
- [24] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” 2019, *arXiv:1810.04805*.
- [25] T. B. Brown et al., “Language Models are Few-Shot Learners,” 2020, *arXiv:2005.14165*.
- [26] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “Bleu: a Method for Automatic Evaluation of Machine Translation,” in *Proc. 40th Annu. Meeting Assoc. Comput. Linguistics*, Philadelphia, Pennsylvania, USA: Association for Computational Linguistics, Jul. 2002, pp. 311–318. doi: 10.3115/1073083.1073135. [Online]. Available: <https://aclanthology.org/P02-1040/>.
- [27] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” in *Text Summarization Branches Out*, Barcelona, Spain: Association for Computational Linguistics, Jul. 2004, pp. 74–81. [Online]. Available: <https://aclanthology.org/W04-1013/>.
- [28] 臺北市勞動力重建運用處. “臺北市手語翻譯培訓教材.” Accessed: May 26, 2025. [Online]. Available: https://fd.gov.taipei/News_Content.aspx?n=33AD377CE79CDD67&sms=777D61CE7A1EE646&s=87A01B9BF9B38744.
- [29] 教育部. “常用手語辭典.” Accessed: May 26, 2025. [Online]. Available: <https://special.moe.gov.tw/signlanguage/>.
- [30] 教育部國民及學前教育署. “學齡前 2 至 6 歲教保服務人員手語手冊.” Accessed: May 26, 2025. [Online]. Available: https://www.ece.moe.edu.tw/ch/special_education/skill/skill_0002/.
- [31] 手語語言學台灣研究中心. “台灣手語線上辭典.” Accessed: May 26, 2025. [Online]. Available: <https://twtsl.ccu.edu.tw/TSL/>.
- [32] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, and C. Raffel, “mT5: A massively multilingual pre-trained text-to-text transformer,” 2021, *arXiv:2010.11934*.
- [33] X. Ming. “text2vec: A Tool for Text to Vector.” Accessed: Jul. 15, 2025. [Online]. Available: <https://github.com/shibing624/text2vec>.
- [34] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” 2021, *arXiv:2106.09685*.
- [35] CKIPLab. “Ckip-transformers Pos Table.” Accessed: May 21, 2025. [Online]. Available: <https://github.com/ckiplab/ckip-transformers/blob/master/docs/main/tag/pos.csv>.

- [36] hankcs. “HanLP Documentation: Universal Dependencies.” Accessed: May 21, 2025. [Online]. Available: <https://hanlp.hankcs.com/docs/annotations/dep/ud.html>.
- [37] hankcs. “HanLP Documentation: Constituency Parsing Chinese Tree Bank.” Accessed: May 21, 2025. [Online]. Available: <https://hanlp.hankcs.com/docs/annotations/constituency/ctb.html>.

附錄 A CKIP 詞性標註對照表

表 A.1: 詞性標註對應索引表 [35]

POS Tag	POS ID	詞性解釋
A	1	非謂形容詞
Caa	2	對等連接詞
Cab	3	連接詞，如「等等」
Cba	4	連接詞，如「的話」
Cbb	5	關聯連接詞
D	6	副詞
Da	7	數量副詞
Dfa	8	動詞前程度副詞
Dfb	9	動詞後程度副詞
Di	10	時態標記
Dk	11	句副詞
DM	12	定量式
I	13	感嘆詞
Na	14	普通名詞
Nb	15	專有名詞
Nc	16	地方詞
Ncd	17	位置詞

(續下頁)

POS Tag	POS ID	詞性解釋
Nd	18	時間詞
Nep	19	指代定詞
Neqa	20	數量定詞
Neqb	21	後置數量定詞
Nes	22	特指定詞
Neu	23	數詞定詞
Nf	24	量詞
Ng	25	後置詞
Nh	26	代名詞
Nv	27	名物化動詞
P	28	介詞
T	29	語助詞
VA	30	動作不及物動詞
VAC	31	動作使動動詞
VB	32	動作類及物動詞
VC	33	動作及物動詞
VCL	34	動作接地方賓語動詞
VD	35	雙賓動詞
VF	36	動作謂賓動詞
VE	37	動作句賓動詞
VG	38	分類動詞
VH	39	狀態不及物動詞
VHC	40	狀態使動動詞
VI	41	狀態類及物動詞
VJ	42	狀態及物動詞
VK	43	狀態句賓動詞

(續下頁)

POS Tag	POS ID	詞性解釋
VL	44	狀態謂賓動詞
V_2	45	「有」動詞
DE	46	的、之、得、地
SHI	47	「是」字
FW	48	外文
COLONCATEGORY	49	冒號
COMMACATEGORY	50	逗號
DASHCATEGORY	51	破折號
DOTCATEGORY	52	點號
ETCCATEGORY	53	刪節號
EXCLAMATIONCATEGORY	54	驚嘆號
PARENTHESISCATEGORY	55	括號
PAUSECATEGORY	56	頓號
PERIODCATEGORY	57	句號
QUESTIONCATEGORY	58	問號
SEMICOLONCATEGORY	59	分號
SPCHANGECATEGORY	60	雙直線
WHITESPACE	61	空白

附錄 B HanLP 標記對照表

表 B.1: 依存句法標記對照表 [36]

Dep Tag	說明	Dep Tag	說明
acl	形容詞子句	det	限定
advcl:loc	狀語從句修飾語	discourse	語氣
advmod	狀語	dobj	直接賓語
advmod:dvp	狀語: 地	etc	省略
advmod:loc	狀語: 限定	mark	標記
advmod:rcomp	狀語: 因果	mark:clf	標記: 量詞
amod	形容	name	名稱
amod:ordmod	形容: 數量	neg	否定
appos	同位	nmod	名詞修飾
aux:asp	助語: 時態	nmod:assmod	名詞修飾: 關聯
aux:ba	助語: 把	nmod:poss	名詞修飾: 所有格
aux:modal	助語: 情態	nmod:prep	名詞修飾: 介詞
aux:prtmod	助語: 分詞	nmod:range	名詞修飾: 範圍
auxpass	被動	nmod:tmod	名詞修飾: 時間
case	條件	nmod:topic	名詞修飾: 主題
cc	並列連詞	nsubj	名詞主語
ccomp	從句補語	nsubj:xsubj	名詞主語: 補語

(續下頁)

Dep Tag	說明	Dep Tag	說明
compound:nn	複合名詞	nsubjpass	被動態主語
compound:vc	複合動詞	nummod	數量
conj	連接	parataxis:prnmod	並列
cop	系動	punct	標點符號
csubj	從句主語	root	根
dep	未定義	xcomp	從句補語

表 B.2: 成分句法標記對照表 [37]

Con Tag	說明
ADVP	副詞短語
ADVP-CMPL	補語副詞短語
ADVP-MSR	度量副詞短語
ADVP-PRD	謂語副詞短語
ADVP-TMP	時間副詞短語
CONJP	連接詞短語
CP-EXL	感嘆語
CP-IMP	祈使句 / 命令語
CP-FINAL	句末助詞的投射
CP-QUE	問句（直接或間接）
CP-QUE-ADV	副詞性問句
CP-QUE-OB1	作為賓語的問句
CP-QUE-PRD	作為名詞性謂語的問句
CP-QUE-SBJ	作為主語的問句
CP-THT	補語子句
CP-THT-ADV	副詞性補語子句
CP-THT-OB1	作為賓語的補語子句
CP-THT-PRD	作為謂語的補語子句
CP-THT-PRP	目的性補語子句
CP-THT-SBJ	作為主語的補語子句
FRAG	片段
FS	錯誤起始
INTJP	感嘆短語
IP-ADV	副詞子句

（續下頁）

Con Tag	說明
IP-ADV-CONJ	並列子句
IP-ADV-PRD	作為謂語的副詞子句
IP-ADV-SCON	從屬子句
IP-ADV-SCON-CND	條件性從屬副詞子句
conditional	子句
IP-EMB	無缺口的名詞修飾子句
IP-IMP	祈使子句
IP-MAT	主句
IP-NMZ	名詞化子句
IP-NMZ-PRD	作為謂語的名詞化子句
IP-REL	關係子句
IP-SMC	小子句
IP-SMC-CNT	持續形式的小子句
IP-SMC-OB1	作為賓語的小子句
IP-SMC-SBJ	作為主語的小子句
IP-SUB	CP* 層下的子句
multi-sentence	複合句
NML	仲介名詞層
NP	名詞短語
NP-ADV	副詞性名詞短語
NP-CZZ	受事名詞短語
NP-DOB1	衍生的主要賓語名詞短語
NP-DSBJ	衍生的主語名詞短語
NP-LGS	邏輯主語名詞短語
NP-LOC	位置名詞短語
NP-MSR	度量名詞短語

(續下頁)

Con Tag	說明
NP-OB1	主要賓語名詞短語
NP-OB2	次要賓語名詞短語
NP-POS	所有格名詞短語
NP-PRD	謂語名詞短語
NP-SBJ	主語名詞短語
NP-SBJ2	次要主語名詞短語
NP-TMP	時間名詞短語
NP-TPC	主題名詞短語
NP-VOC	稱呼語名詞短語
NUMCLP	數詞-分類詞短語
PNLP	前置名詞短語
PP	助詞短語
PP-ADV	副詞性助詞短語
PP-CMPL	補語助詞短語
PP-CONJ	並列助詞短語
PP-CZZ	受事助詞短語
PP-DOB1	衍生的主要賓語助詞短語
PP-DSBJ	衍生的主語助詞短語
PP-LGS	邏輯主語助詞短語
PP-LOC	位置助詞短語
PP-MSR	度量助詞短語
PP-OB1	主要賓語助詞短語
PP-OB2	次要賓語助詞短語
PP-PRD	謂語助詞短語
PP-PRP	目的性助詞短語
PP-SBJ	主語助詞短語

(續下頁)

Con Tag	說明
PP-SBJ2	次要主語助詞短語
PP-SCON	從屬助詞短語
PP-SCON-CND	條件性助詞短語
PP-TMP	時間助詞短語
PP-TPC	主題助詞短語
PP-VOC	稱呼語助詞短語
PRN	插入語
ADJP	形容詞短語，以形容詞為中心詞
ADVP	副詞短語，以副詞為中心詞
CLP	由量詞構成的短語
CP	從句，通過帶補語（如“的”、“嗎”等）
DNP	結構為 XP + DEG(的) 的短語，其中 XP 可以是 ADJP、DP、QP、PP 等等，用於修飾名詞短語。
DP	限定詞短語，通常由限定詞和數量詞構成
DVP	結構為 XP+ 地的短評，用於修飾動詞短語 VP
FRAG	片段
INTJ	插話，感歎語
IP	簡單子句或句子，通常不帶補語（如“的”、“嗎”等）
LCP	用於表本地點 + 方位詞（LC）的短語
LST	列表短語，包括標點符號
MSP	其他小品詞
NN	名詞
NP	名詞短語，中心詞通常為名詞
PP	介詞短語，中心詞通常為介詞
PRN	插入語
QP	量詞短語

（續下頁）

Con Tag	說明
TOP	根節點
UCP	不對稱的並列短語，指並列詞兩側的短語類型不致
VCD	複合動詞
VCP	VV + VC 形式的動詞短語
VNV	V 不 V 形式的動詞短語
VP	動詞短語，中心詞通常為動詞
VPT	V 不 R、V 得 R 形式的動詞短語
VRD	動補結構短語
VSB	修飾語 + 中心詞構成的動詞短語